





MCDI

Maestría en Ciencia de
Datos e Información

INFOTEC CENTRO DE INVESTIGACIÓN E
INNOVACIÓN EN TECNOLOGÍAS DE LA
INFORMACIÓN Y COMUNICACIÓN

DIRECCIÓN ADJUNTA DE INNOVACIÓN Y
CONOCIMIENTO
GERENCIA DE CAPITAL HUMANO
POSGRADOS

Estratificación de riesgo clínico consciente de la equidad

**Auditoría y mitigación del sesgo
geográfico entre entidades federativas
en modelos predictivos con datos
abiertos de salud de México**

(TESIS)

Que para obtener el grado de MAESTRO EN
CIENCIA DE DATOS E INFORMACIÓN

Presenta:

David Segundo García

Asesor:

Dr. Daniel Alejandro Cervantes Cabrera

Ciudad de México, agosto, 2026.

Autorización de impresión

Agradecimientos

Índice general

Índice de figuras	vii
Índice de tablas	viii
Abreviaturas y acrónimos	ix
Glosario	x
Resumen	xii
Presentación	1
Capítulo 1. Introducción	4
1.1 Planteamiento del problema.....	4
1.1.1 El sesgo algorítmico en salud como problema documentado	5
1.2 Preguntas de investigación.....	5
1.3 Objetivos	6
1.3.1 Objetivo general	6
1.3.2 Objetivos específicos	6
1.4 Hipótesis.....	6
1.5 Contribuciones esperadas.....	7
1.6 Justificación	7
1.6.1 Aporte al perfil del programa	8
1.7 Alcance y delimitaciones	9
Capítulo 2. Marco teórico y trabajos relacionados.....	11
2.1 Antecedentes	11
2.1.1 Estudios previos sobre predicción de desenlaces en México.....	11
2.1.2 Antecedentes sobre el sesgo algorítmico en salud.....	12
2.1.3 Contexto académico del problema.....	12
2.2 Estado del arte	13
2.2.1 La parte predictiva mexicana está saturada	13
2.2.2 Lo geográfico ya se estudió, pero como predictor.....	14
2.2.3 La equidad algorítmica en salud es madura, pero fuera de México	14
2.2.4 Tendencias, vacíos y áreas de oportunidad	15
2.3 Bases teóricas	16

2.3.1 Evaluación de modelos de riesgo clínico.....	16
2.3.2 Aprendizaje automático sobre datos tabulares	17
2.3.3 Criterios formales de equidad algorítmica	17
2.3.4 El teorema de imposibilidad	18
2.3.5 Técnicas de mitigación del sesgo	18
2.3.6 La frontera de Pareto como instrumento de decisión.....	19
2.4 Marco conceptual.....	19
2.4.1 Conceptos centrales	20
2.4.2 Variables del estudio	21
2.4.3 Definiciones operacionales de las métricas	21
Capítulo 3. Metodología	24
3.1 Fuente de datos y construcción de la cohorte	24
3.1.1 Fuentes de información	24
3.1.2 Construcción de la cohorte y definición del desenlace.....	25
3.1.3 Creación y definición de nuevas variables	26
3.2 Preprocesamiento de los datos.....	27
3.2.1 Control de fuga de información	27
3.2.2 Limpieza y recodificación.....	27
3.2.3 Partición de datos.....	28
3.3 Análisis exploratorio de los datos	28
3.3.1 Calidad del dato y estructura de la ausencia.....	28
3.3.2 Heterogeneidad entre entidades federativas.....	29
3.3.3 Distribución del riesgo y del desenlace.....	30
Conclusiones y recomendaciones.....	33
Fuentes de consulta	35
ANEXO 1	39
Variables admitidas y excluidas del modelo.....	39

Índice de figuras

Figura 1. Heterogeneidad entre entidades federativas en la cohorte: tasa de defunción (izquierda) y tamaño de muestra (derecha).	30
Figura 2. Análisis exploratorio de la cohorte 2021: distribución de las variables predictoras y su relación con el desenlace.	31

Índice de tablas

Tabla 1. Posición de esta tesis respecto de la literatura.	15
Tabla 2. Variables del estudio y sus definiciones operacionales.	21
Tabla 3. Definiciones operacionales de las métricas por dimensión de evaluación.....	21
Tabla 4. Estructura de la ausencia en las variables clínicas de la cohorte.	29
Tabla 5. Variables de la base de la DGE y su tratamiento en el estudio.	39

Abreviaturas y acrónimos

Sigla	Descripción
AUPRC	Área bajo la curva de precisión y exhaustividad (del inglés “Area Under the Precision-Recall Curve”)
AUROC	Área bajo la curva ROC (del inglés “Area Under the Receiver Operating Characteristic Curve”)
CONAPO	Consejo Nacional de Población
COVID-19	Enfermedad por coronavirus 2019 (del inglés “Coronavirus Disease 2019”)
DGE	Dirección General de Epidemiología, Secretaría de Salud
DGIS	Dirección General de Información en Salud, Secretaría de Salud
EDA	Análisis exploratorio de datos (del inglés “Exploratory Data Analysis”)
EPOC	Enfermedad pulmonar obstructiva crónica
FPR	Tasa de falsos positivos (del inglés “False Positive Rate”)
HGB	Impulso del gradiente por histogramas (del inglés “Histogram-based Gradient Boosting”)
IA	Inteligencia artificial (del inglés “Artificial Intelligence”)
INEGI	Instituto Nacional de Estadística y Geografía
INFOTEC	Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación
MCDI	Maestría en Ciencia de Datos e Información
ML	Aprendizaje automático (del inglés “Machine Learning”)
ROC	Característica operativa del receptor (del inglés “Receiver Operating Characteristic”)
SHAP	Explicaciones aditivas de Shapley (del inglés “SHapley Additive exPlanations”)
TPR	Tasa de verdaderos positivos o sensibilidad (del inglés “True Positive Rate”)
TRIPOD	Guía de reporte transparente de modelos de predicción multivariable (del inglés “Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis”)
UCI	Unidad de cuidados intensivos

Glosario

“A”

AUROC: Área bajo la curva ROC. Resume la capacidad de un modelo para ordenar correctamente a los pacientes por riesgo. Es insensible a transformaciones monótonas del puntaje, por lo que no informa sobre la calidad de las probabilidades emitidas.

AUPRC: Área bajo la curva de precisión y exhaustividad. Complementa al AUROC en cohortes con desenlaces poco frecuentes, porque es sensible al desbalance de clases.

Atributo sensible: Variable respecto de la cual se exige que el comportamiento del modelo sea equitativo. En este trabajo, la entidad federativa de residencia.

Auditoría de equidad: Evaluación del desempeño de un modelo desagregado por los valores de un atributo sensible, con el fin de detectar disparidades sistemáticas.

“C”

Calibración: Correspondencia entre la probabilidad predicha y la frecuencia observada del desenlace. Un modelo está calibrado si, entre los pacientes a quienes asigna un riesgo de 20 %, fallece aproximadamente el 20 %.

Cohorte: Conjunto de registros que satisfacen los criterios de inclusión del estudio. Aquí, los casos COVID confirmados del corte anual 2021.

Conjunto de calibración: Bloque de datos reservado exclusivamente para ajustar la transformación de calibración y los umbrales por grupo, sin intervenir en el entrenamiento ni en la evaluación final.

“D”

Discriminación: Capacidad de un modelo para ordenar a los pacientes por riesgo. Se distingue de la calibración, que se refiere al nivel absoluto de la probabilidad estimada.

Definición operacional: Traducción de un concepto a una regla de cálculo verificable sobre los datos disponibles.

“E”

Equalized odds: Criterio de equidad que exige igualdad simultánea de sensibilidad y tasa de falsos positivos entre grupos. Su relajación al caso de los positivos se conoce como igualdad de oportunidades.

Estratificación de riesgo: Asignación de una probabilidad de desenlace adverso a cada paciente con el fin de ordenar la atención.

“F”

Frontera de Pareto: Conjunto de políticas de despliegue tales que no existe otra que mejore la equidad sin empeorar el desempeño, ni al contrario. Es el instrumento con el que este trabajo hace explícito el compromiso entre ambos objetivos.

Fuga de información: Uso como predictor de información no disponible en el punto de predicción. Produce un desempeño aparente que no se reproduce en despliegue.

“P”

Paridad demográfica: Criterio de equidad que exige igual tasa de selección entre grupos, sin condicionar al desenlace observado.

Punto de operación: Umbral de decisión que convierte el puntaje de riesgo en una acción. Todas las métricas dependientes de umbral se reportan en un punto de operación único y declarado.

Punto de predicción: Momento del proceso de atención en el que el modelo emitiría su estimación. En este trabajo, el primer contacto.

“R”

Regresión isotónica: Transformación monótona, ajustada sobre datos no vistos, que corrige el nivel de las probabilidades sin alterar el ordenamiento y por tanto sin afectar al AUROC.

“S”

Sesgo geográfico: Diferencia sistemática en la calidad de las predicciones del modelo entre entidades federativas. No debe confundirse con la diferencia de riesgo entre entidades, que es un hecho epidemiológico.

Sensibilidad: Proporción de casos con desenlace positivo que el modelo marca correctamente como de riesgo, en el punto de operación establecido.

“T”

Teorema de imposibilidad: Resultado según el cual, si la prevalencia del desenlace difiere entre grupos y el clasificador no es perfecto, la calibración por grupo y equalized odds no pueden satisfacerse a la vez.

Transportabilidad: Grado en que el desempeño y la equidad de un modelo se conservan al aplicarlo a una población o fuente distinta de la de ajuste.

Resumen

Existe una literatura amplia que predice hospitalización y mortalidad por COVID-19 con datos mexicanos, y su desempeño puede considerarse un problema resuelto. Esta tesis desplaza el objeto de estudio: no pregunta si un modelo acierta, sino **si acierta por igual**, con énfasis en el sesgo geográfico entre entidades federativas, una dimensión asociada a la desigualdad estructural del sistema de salud en México y prácticamente inexplorada.

El trabajo se apoya en la base abierta de COVID-19 de la Dirección General de Epidemiología (DGE), restringida a casos confirmados del año 2021 ($n = 2\,526\,649$; mortalidad observada 5.60 %). Sobre esa cohorte se construye un canal reproducible de ingesta, limpieza y preparación con control estricto de fuga de información, se entrena un modelo de referencia de mortalidad al primer contacto y se calibra mediante regresión isotónica sobre un bloque independiente. Ese modelo es el sujeto de una auditoría de equidad por entidad federativa, sexo y grupo etario, y de las tres familias de mitigación de sesgo —pre, in y post-procesamiento— evaluadas sobre un punto de operación clínico común de 80 % de sensibilidad.

El presente documento corresponde a la primera entrega del proyecto terminal y reporta los tres primeros capítulos: la introducción, con el planteamiento del problema y el protocolo de investigación; el marco teórico —antecedentes, estado del arte, bases teóricas y marco conceptual—; y la metodología, con la construcción y caracterización de la base de datos. La contribución esperada es la primera auditoría de equidad geográfica de un modelo clínico sobre datos abiertos

mexicanos, acompañada de una frontera de Pareto equidad–desempeño utilizable como instrumento de decisión antes del despliegue.

Palabras clave: equidad algorítmica, sesgo geográfico, estratificación de riesgo, COVID-19, datos abiertos de salud, calibración, equalized odds, frontera de Pareto.

Presentación

La saturación hospitalaria y la asignación de recursos escasos son retos persistentes del sistema de salud mexicano. Contar con herramientas que estimen tempranamente el riesgo de un desenlace grave permite priorizar la atención y anticipar necesidades de camas y ventiladores. La literatura reciente muestra, sin embargo, que el problema puramente predictivo ya está ampliamente resuelto para el caso mexicano: existen múltiples modelos con buen desempeño sobre la base abierta de la Secretaría de Salud (Becerra-Sánchez et al., 2022; Méndez-Astudillo, 2024).

El problema no abordado es otro. Un modelo puede tener excelente desempeño promedio y, al mismo tiempo, ser sistemáticamente menos preciso para habitantes de entidades con menor infraestructura, para personas mayores o para un sexo determinado. En un país tan heterogéneo como México, un modelo entrenado con datos dominados por entidades urbanas puede desempeñarse peor justo donde el sistema de salud es más débil, amplificando la inequidad en lugar de reducirla. Diagnosticar y corregir esa inequidad —especialmente la geográfica— sin sacrificar de forma inaceptable la utilidad clínica del modelo es el problema central de este trabajo.

Esta primera entrega comprende los tres primeros capítulos del proyecto terminal. El **capítulo 1** es la introducción: fija el planteamiento del problema y el protocolo de investigación —preguntas, objetivos e hipótesis—, la justificación, las contribuciones esperadas y los límites y alcances de lo que aquí se reporta. El **capítulo 2** desarrolla el marco teórico en cuatro apartados: los antecedentes del problema, el estado del arte con el análisis crítico de las investigaciones recientes, las bases teóricas que sustentan la auditoría de equidad y el marco conceptual con las definiciones operacionales que se emplean en el resto de la tesis. El **capítulo 3** documenta la metodología: las fuentes de información, la construcción de la cohorte de análisis, la definición de variables nuevas, el preprocesamiento con control de fuga de información y el análisis exploratorio que caracteriza la heterogeneidad entre entidades federativas.

Un criterio recorre todo el documento y conviene enunciarlo desde el principio: la revisión crítica de modelos pronósticos de COVID-19 documentó que la mayoría presentaba alto riesgo de sesgo por selección de cohorte, fuga de información y ausencia de validación (Wynants et al., 2020). Las decisiones de este trabajo —la restricción a casos confirmados, la exclusión explícita de variables posteriores al punto de predicción y la partición en tres bloques— se toman para no repetir esos defectos, y se documentan con el detalle que exigen las guías de reporte de modelos predictivos en salud (Collins et al., 2015).

Capítulo 1

Introducción



Capítulo 1. Introducción

Este capítulo introduce el proyecto terminal. Delimita el problema que se aborda, formula el protocolo de investigación que lo estructura —preguntas, objetivos e hipótesis—, argumenta su pertinencia, enuncia las contribuciones esperadas y fija con precisión los límites de lo que se reporta. El propósito del último apartado merece subrayarse: los límites no son concesiones retóricas, sino la condición para que los resultados de los capítulos siguientes se lean correctamente.

1.1 Planteamiento del problema

La saturación hospitalaria y la asignación de recursos escasos son retos persistentes del sistema de salud mexicano. Contar con herramientas que estimen tempranamente el riesgo de un desenlace grave permite priorizar la atención y anticipar necesidades de camas y ventiladores. La literatura reciente muestra, sin embargo, que el problema puramente predictivo ya está ampliamente resuelto para el caso mexicano: existen múltiples modelos con buen desempeño (Becerra-Sánchez et al., 2022; Méndez-Astudillo, 2024).

El problema no abordado es otro. Un modelo puede tener excelente desempeño promedio y, al mismo tiempo, ser sistemáticamente menos preciso para habitantes de entidades con menor infraestructura, para personas mayores o para un sexo determinado. Esa posibilidad no es hipotética, y el apartado siguiente documenta el caso de referencia.

En un país tan heterogéneo como México, un modelo entrenado con datos dominados por entidades urbanas puede desempeñarse peor justo donde el sistema de salud es más débil, amplificando la inequidad en lugar de reducirla. El problema central de esta tesis es, por tanto, **diagnosticar y corregir la inequidad del modelo —especialmente la geográfica— sin sacrificar de forma inaceptable su utilidad clínica.**

La formulación importa porque el objeto de estudio se desplaza. No se pregunta si un modelo de riesgo acierta, cuestión ya resuelta en este dominio, sino si acierta por igual entre grupos de población, y qué puede hacerse cuando no lo hace. Ese

desplazamiento cambia el instrumento de evaluación: las métricas agregadas de desempeño resultan insuficientes y deben acompañarse de métricas de disparidad desagregadas por grupo.

1.1.1 El sesgo algorítmico en salud como problema documentado

El caso mejor documentado de sesgo algorítmico en salud es un modelo de gestión poblacional en Estados Unidos que asignaba menos recursos a pacientes afroamericanos con igual carga de enfermedad. El mecanismo es instructivo: el sesgo no provenía de usar la raza como predictor —el modelo no la usaba—, sino de que el desenlace elegido, el gasto sanitario, estaba ya distorsionado por el acceso desigual a los servicios (Obermeyer et al., 2019). Un modelo técnicamente correcto reprodujo así una desigualdad preexistente.

La lección para este trabajo es directa y condiciona el diseño de los capítulos siguientes. Primero, la ausencia del atributo sensible entre los predictores no garantiza equidad; por eso la entidad federativa se excluye deliberadamente como variable de entrada y se reserva como eje de auditoría. Segundo, la inequidad puede estar inscrita en la definición del desenlace y en el proceso de captura del dato, no solo en el algoritmo; por eso el capítulo 3 documenta con detalle cómo se registran los datos y qué significan sus códigos de ausencia.

1.2 Preguntas de investigación

El protocolo de investigación articula el problema anterior en preguntas contrastables, objetivos verificables e hipótesis que pueden resultar falsas. Se enuncia con etiquetas explícitas —P, OE, H— porque los capítulos posteriores referencian cada elemento de forma individual al reportar en qué medida quedó atendido.

- **P1.** Dado un modelo de riesgo con buen desempeño global sobre datos mexicanos, ¿existen disparidades de desempeño entre entidades federativas, grupos etarios y sexos?
- **P2.** ¿Cómo se relaciona la magnitud del sesgo geográfico con indicadores de infraestructura o marginación de cada entidad?

- **P3.** ¿Qué técnicas de mitigación —pre, in y post-procesamiento— reducen mejor esas disparidades, y cuál es el costo en desempeño global expresado como frontera de Pareto?
- **P4.** ¿Se transfieren tanto el desempeño como la equidad del modelo a una fuente de datos independiente?
- **P5.** De forma exploratoria, ¿aparecen inequidades adicionales en subgrupos interseccionales, por ejemplo adultos mayores de entidades marginadas?

1.3 Objetivos

1.3.1 Objetivo general

Desarrollar, auditar y mitigar la equidad —con énfasis en el sesgo geográfico entre entidades federativas— de un modelo de estratificación de riesgo clínico basado en datos abiertos de salud de México, valorando la transportabilidad de sus hallazgos.

1.3.2 Objetivos específicos

- **OE1.** Construir un canal reproducible de ingesta, limpieza y preparación de la base de la DGE, con control estricto de fuga de información.
- **OE2.** Entrenar un modelo de riesgo de referencia con desempeño comparable al estado del arte, como sujeto del análisis de equidad.
- **OE3.** Auditar la equidad del modelo por entidad federativa, sexo y grupo etario, y examinar la asociación del sesgo geográfico con indicadores contextuales.
- **OE4.** Aplicar y comparar técnicas de mitigación en las tres etapas del canal, construyendo la frontera de Pareto entre equidad y desempeño.
- **OE5.** Explorar la equidad en subgrupos interseccionales y traducir los hallazgos a recomendaciones de despliegue.

1.4 Hipótesis

- **H1.** Un modelo con buen desempeño global presentará disparidades de desempeño entre entidades federativas, medibles por equalized odds y calibración por grupo.
- **H2.** La magnitud del sesgo geográfico se asociará negativamente con la infraestructura de salud de cada entidad: peor desempeño donde hay menos recursos.
- **H3.** Las técnicas de mitigación reducirán las disparidades con una pérdida de desempeño global inferior a un umbral predefinido, cuantificable mediante la frontera de Pareto.
- **H4.** El desempeño se transferirá razonablemente a una fuente independiente, pero las disparidades podrían acentuarse, evidenciando la necesidad de recalibrado por contexto.

1.5 Contribuciones esperadas

- La primera auditoría de equidad geográfica —entidad federativa como atributo sensible— de un modelo de riesgo clínico entrenado sobre datos abiertos mexicanos.
- Una comparación de las tres familias de mitigación bajo un punto de operación clínico común, que permite documentar si alguna resulta sistemáticamente superior cuando los grupos son numerosos y de tamaño muy desigual.
- Una frontera de Pareto equidad–desempeño construida con umbrales estimados fuera de muestra, y la cuantificación del optimismo que introduce estimarlos en el propio conjunto de prueba.
- Un canal reproducible con contrato de datos explícito entre etapas, que verifica procedencia, esquema y cohorte antes de consumir cualquier artefacto intermedio.

1.6 Justificación

La relevancia del proyecto se sostiene en cinco pilares.

Viabilidad de los datos. La base de la DGE es pública, masiva y con desenlace claro, lo que permite comenzar de inmediato sin trámites de acceso ni convenios institucionales. Es una ventaja poco frecuente en investigación con datos clínicos y elimina el riesgo más común de este tipo de proyecto: quedarse sin datos.

Pertinencia nacional. Al usar datos del propio sistema de salud mexicano y tratar la entidad federativa como eje, los hallazgos son directamente transferibles a la política de salud del país. La organización federal de los servicios de salud hace que «entidad» no sea una variable demográfica cualquiera, sino la unidad en la que efectivamente se decide y se financia la atención.

Originalidad documentada. La equidad geográfica de modelos clínicos sobre datos mexicanos es un vacío identificado en la revisión del capítulo 2, no una suposición: la búsqueda no arrojó ningún trabajo que trate la entidad federativa como atributo sensible en una auditoría de equidad algorítmica.

Impacto en la decisión. Una frontera de Pareto equidad–desempeño es un insumo concreto para quien deba autorizar el despliegue de un modelo: convierte una disyuntiva que suele discutirse en abstracto en un conjunto de políticas explícitas, cada una con su costo medido. La elección entre ellas es normativa, y el entregable la hace visible en lugar de esconderla en un valor por omisión.

Oportunidad regulatoria. La discusión sobre uso responsable de inteligencia artificial en el sector público mexicano está en curso. Un estudio que muestre cómo auditar un modelo de salud antes de desplegarlo, con datos nacionales y método reproducible, aporta un caso de referencia y no solo un resultado.

1.6.1 Aporte al perfil del programa

El trabajo se ubica en el núcleo de la Maestría en Ciencia de Datos e Información: integra ingesta y preparación de datos masivos, modelado supervisado, evaluación estadística rigurosa y traducción de resultados a decisiones. Requiere además una competencia que el programa enfatiza y que este proyecto ejercita de forma explícita: la capacidad de auditar críticamente un sistema analítico, incluido el propio.

1.7 Alcance y delimitaciones

Para que la lectura de los resultados sea correcta conviene fijar con precisión sus límites. Los siguientes acotan el alcance de lo que este trabajo puede afirmar.

- **Cohorte.** Casos COVID confirmados ($CLASIFICACION_FINAL \in \{1, 2, 3\}$) del corte anual 2021 de la base de la DGE, $n = 2\,526\,649$. No se emplea la serie histórica completa de la pandemia.
- **Desenlace.** Mortalidad. La hospitalización se deriva y se describe en el análisis exploratorio, pero no se modela en este documento. En esta cohorte fallecer implica estar registrado como hospitalizado, de modo que el desenlace solo es posible en el 11.8 % de los casos; el capítulo 3 documenta esa propiedad estructural y el análisis de sensibilidad previsto examina sus consecuencias.
- **Validación externa.** La transportabilidad a la base de Egresos Hospitalarios de la DGIS (Dirección General de Información en Salud, 2024), que sustenta H4, no se ha ejecutado, y H4 se reporta como trabajo pendiente. Sí se evalúa la generalización geográfica dentro de la misma fuente, lo que no la sustituye.
- **Indicadores contextuales.** El examen de H2 se apoya en el índice de marginación por entidad de CONAPO 2020 (Consejo Nacional de Población, 2021), que es un agregado socioeconómico estatal. No se emplearon indicadores de infraestructura de salud por unidad médica, que serían el proxy más directo del mecanismo que H2 postula.
- **Interpretabilidad.** Se emplea importancia por permutación. No se calcularon valores SHAP ni análisis de curva de decisión (Vickers y Elkin, 2006).
- **Alcance de esta entrega.** El presente documento cubre el marco general, la base de datos y el marco teórico. El ajuste de modelos, la auditoría de equidad, la mitigación y la discusión de resultados corresponden a las entregas siguientes del proyecto terminal.

Los límites anteriores no son concesiones retóricas. Cualquier afirmación de esta tesis que dependa de H4 o de intervalos de confianza se marca como preliminar en el punto donde aparece.



Capítulo 2

Marco teórico

Capítulo 2. Marco teórico y trabajos relacionados

Este capítulo construye el marco teórico del proyecto en cuatro apartados. El primero expone los antecedentes: qué se ha hecho antes sobre este problema y en qué contexto académico se inscribe. El segundo analiza críticamente el estado del arte, comparando enfoques y resultados hasta identificar el vacío que el trabajo ocupa. El tercero desarrolla las bases teóricas —los modelos y teoremas que sustentan la auditoría de equidad— y el cuarto fija el marco conceptual, con las definiciones operacionales que se emplean en el resto de la tesis.

2.1 Antecedentes

Los antecedentes de este trabajo provienen de tres tradiciones que hasta ahora han avanzado por separado: la predicción de desenlaces por COVID-19 con datos mexicanos, la epidemiología espacial de la mortalidad en México y la equidad algorítmica en salud desarrollada en otros países. El problema de esta tesis vive precisamente en la intersección que ninguna de las tres ha ocupado.

2.1.1 Estudios previos sobre predicción de desenlaces en México

Desde la publicación de la base abierta de la DGE en 2020, un número considerable de trabajos ha construido modelos de riesgo sobre ella. Dos son representativos por su alcance y por estar revisados por pares. Becerra-Sánchez et al. (2022) comparan varios algoritmos sobre datos mexicanos y alcanzan alrededor de 90 % de exactitud, identificando neumonía, edad avanzada e intubación como principales factores asociados a la mortalidad. Méndez-Astudillo (2024) aplica random forest y gradient boosting sobre más de veinte millones de observaciones y concluye que diabetes e hipertensión, junto con la desigualdad económica, definen la mortalidad.

Ambos comparten estructura: un clasificador supervisado, atribución de importancia sobre comorbilidades y evaluación mediante métricas agregadas. Es la línea que se toma aquí como punto de partida, no como aportación.

2.1.2 Antecedentes sobre el sesgo algorítmico en salud

El antecedente fundacional del problema de equidad es el estudio de la asignación de recursos en un sistema de salud estadounidense, donde un modelo de gestión poblacional asignaba menos atención a pacientes afroamericanos con igual carga de enfermedad (Obermeyer et al., 2019). Su valor como antecedente no está en la magnitud del sesgo, sino en el mecanismo: el desenlace elegido —el gasto sanitario— era un proxy contaminado por el acceso desigual. El sesgo estaba en la definición del problema, no en el algoritmo.

Un antecedente de otra naturaleza, pero decisivo para el diseño, es la revisión crítica de modelos pronósticos de COVID-19 de Wynants et al. (2020): la mayoría de los modelos revisados presentaba alto riesgo de sesgo, principalmente por selección de cohorte, fuga de información y ausencia de validación. Junto con la guía TRIPOD de reporte de modelos predictivos en salud (Collins et al., 2015), esa revisión define el estándar metodológico que este trabajo se compromete a cumplir y explica varias decisiones del capítulo 3 que de otro modo parecerían excesivamente conservadoras.

2.1.3 Contexto académico del problema

El problema se sitúa en la confluencia de tres campos. De la **informática médica** toma el objeto —los modelos de predicción clínica— y sus estándares de evaluación y reporte. Del **aprendizaje automático justo**, subcampo consolidado en la última década, toma los criterios formales de equidad, los resultados de imposibilidad y las técnicas de mitigación. De la **salud pública** toma la pregunta que da sentido a las dos anteriores: quién queda peor atendido, y si un sistema técnico nuevo corrige o amplifica una desigualdad que ya existía.

La particularidad del caso mexicano justifica tratarlo por separado y no como una aplicación más. La organización federal de los servicios de salud hace que la entidad federativa no sea una variable demográfica cualquiera, sino la unidad en la que se decide, se financia y se opera la atención. Un atributo sensible que coincide con la unidad administrativa de decisión tiene una propiedad poco común: la

mitigación por grupo es, en este contexto, administrativamente implementable, algo que rara vez ocurre con atributos como la raza o el sexo.

2.2 Estado del arte

Este apartado analiza críticamente la producción reciente, comparando enfoques y resultados en lugar de describirlos en serie. La revisión se apoya en fuentes verificadas individualmente contra el registro del editor y sostiene tres afirmaciones que, juntas, delimitan el vacío que este trabajo ocupa.

2.2.1 La parte predictiva mexicana está saturada

La comparación de los trabajos disponibles sobre la base mexicana arroja un patrón de convergencia. Becerra-Sánchez et al. (2022) y Méndez-Astudillo (2024) emplean cohortes, algoritmos y periodos distintos, y sin embargo coinciden en el desempeño alcanzado y en el conjunto de variables informativas —edad, neumonía y las comorbilidades metabólicas—. Esa convergencia es la evidencia más fuerte de saturación: cuando estudios independientes con métodos diferentes llegan al mismo techo, el margen de mejora ya no está en el algoritmo.

La implicación metodológica es directa: replicar el esquema «clasificador más atribución de importancia sobre comorbilidades» sería un trabajo derivativo. Por eso el modelo predictivo se adopta aquí como línea de base y no como aportación. La comparación con esta literatura debe además hacerse con cautela, porque los trabajos de referencia reportan exactitud y F1 y no AUROC, de modo que las cifras no son directamente homologables.

Un examen crítico de esta literatura revela un problema que condiciona el diseño de este trabajo. La variable INTUBADO, que aparece entre los factores más informativos en parte de ella, describe el curso hospitalario y no está disponible al primer contacto. Usarla como predictor de mortalidad en ese punto constituye fuga de información, precisamente el defecto que Wynants et al. (2020) señalan como más frecuente. Esta tesis la excluye explícitamente, lo que hace esperable un desempeño algo menor que el reportado por los trabajos que la incorporan.

2.2.2 Lo geográfico ya se estudió, pero como predictor

Maldonado-Sifuentes et al. (2024) muestran que los factores de ubicación — municipio, unidad médica, entidad de nacimiento y de residencia— superan incluso a la edad como predictores de mortalidad por COVID-19 en México. Es un hallazgo relevante que debe reconocerse, y es el trabajo más cercano al de esta tesis en la literatura nacional. Responde, sin embargo, a una pregunta distinta.

La diferencia es sustantiva y vale la pena precisarla, porque de ella depende la originalidad de este trabajo. Ese estudio usa la geografía como variable de **entrada** para responder «¿dónde vives predice tu desenlace?», una pregunta de epidemiología espacial e importancia de variables. Esta tesis usa la geografía como eje de **auditoría** para responder «¿el modelo comete más errores en unas entidades que en otras, y cómo se corrige esa inequidad?», una pregunta de equidad algorítmica y mitigación. Que la entidad sea informativa como predictor no dice nada sobre si el modelo es igualmente confiable en cada entidad: son propiedades independientes, y de hecho un modelo que **no** use la entidad puede aun así rendir de forma desigual entre ellas.

2.2.3 La equidad algorítmica en salud es madura, pero fuera de México

La literatura de equidad en salud es rica y está anclada en otros contextos y otros atributos sensibles. Nejadshamsi et al. (2026) auditan y mitigan el sesgo por sexo en clasificación de severidad de COVID-19 con datos de Canadá, y es el trabajo metodológicamente más próximo al diseño que aquí se propone. En imagen médica, Ricci Lara et al. (2022) documentan de forma sistemática cómo los sesgos de composición de las cohortes de entrenamiento se trasladan al desempeño por subgrupo.

El contraste con esta literatura revela dos vacíos, no uno. El primero es geográfico en el sentido trivial: no se identificó trabajo alguno que use datos mexicanos tratando la entidad federativa como atributo sensible ligado a la desigualdad de infraestructura de salud. El segundo es metodológico y más interesante: la literatura de equidad trabaja casi siempre con dos o tres grupos de tamaño comparable — hombre/mujer, dos o tres categorías raciales—, mientras que auditar 32 entidades

cuyo tamaño de muestra varía por un factor de 43 plantea un problema estadístico distinto. Con muchos grupos pequeños, los estimadores de brecha máxima están sesgados al alza y los métodos que optimizan esa brecha tienden a perseguir ruido. Este trabajo opera en ese régimen, poco explorado.

2.2.4 Tendencias, vacíos y áreas de oportunidad

El análisis anterior permite identificar tres tendencias. La primera es el desplazamiento del interés desde el desempeño agregado hacia el desempeño desagregado por subgrupo, visible tanto en las guías de reporte como en la literatura de equidad. La segunda es el reconocimiento de que la calibración, y no solo la discriminación, es un requisito para el uso clínico. La tercera es el abandono de la búsqueda de un único «modelo justo» en favor de instrumentos que expliciten el intercambio entre criterios, consecuencia directa de los resultados de imposibilidad del apartado 2.3.

La tabla 1 sintetiza la posición de este trabajo respecto de la literatura revisada.

Tabla 1. Posición de esta tesis respecto de la literatura.

Dimensión	Estado en la literatura	Aporte de esta tesis
Predicción de desenlace (México)	Saturado	Línea de base, no aportación
Geografía como predictor (México)	Estudiado	Se distingue: geografía como eje de equidad
Equidad algorítmica en salud	Madura, fuera de México	Se traslada y adapta al contexto mexicano
Auditoría de equidad por entidad (México)	No identificado	Eje central y original
Mitigación y frontera de Pareto (México)	No identificado	Instrumento de decisión entregable
Equidad con muchos grupos desiguales	Poco explorada	Régimen de trabajo: 32 grupos, factor 43 de tamaño
Transportabilidad de la equidad	Rara vez evaluada	Validación interna; externa como trabajo pendiente

En una frase: sabemos que la geografía predice la mortalidad en México y que la equidad algorítmica importa en otros países, pero nadie ha preguntado todavía si un modelo clínico entrenado con datos mexicanos es igual de preciso entre entidades federativas, ni cómo corregir esa inequidad.

2.3 Bases teóricas

Este apartado desarrolla los modelos y resultados formales que sustentan la investigación. Se organizan en tres bloques: la teoría de evaluación de modelos de riesgo clínico, la de aprendizaje automático sobre datos tabulares y la de equidad algorítmica, que aporta el resultado teórico central del trabajo.

2.3.1 Evaluación de modelos de riesgo clínico

Un modelo de estratificación de riesgo estima la probabilidad de un desenlace — aquí, la defunción— a partir de información disponible en el momento en que se toma la decisión clínica. Su evaluación exige separar dos propiedades que se confunden con frecuencia.

La **discriminación** mide la capacidad de ordenar pacientes por riesgo y se resume en el AUROC. Es insensible a transformaciones monótonas del puntaje: un modelo puede discriminar perfectamente y, aun así, emitir probabilidades absurdas. La **calibración** mide justamente eso: si de cada cien pacientes a quienes el modelo asigna un riesgo de 20 % fallecen efectivamente veinte. Van Calster et al. (2019) argumentan que la calibración es el talón de Aquiles de la analítica predictiva en medicina, porque un modelo descalibrado desplaza sistemáticamente las decisiones de umbral sin que el AUROC lo delate.

Esa distinción es la base teórica de una decisión central de este trabajo: la auditoría de equidad se realiza sobre el puntaje **calibrado**. La razón es que, sin calibrar, el error de calibración medido por grupo queda dominado por el sesgo global de entrenamiento y no por la inequidad entre grupos, que es el objeto de estudio.

En cohortes con desenlaces poco frecuentes, el AUPRC complementa al AUROC porque es sensible al desbalance de clases. Y como toda métrica agregada oculta la distribución de errores, la evaluación de un modelo destinado al despliegue debe reportarse en el **punto de operación** previsto y no en un umbral arbitrario. Las guías de reporte recogen estos requisitos de manera sistemática (Collins et al., 2015).

2.3.2 Aprendizaje automático sobre datos tabulares

Para datos tabulares heterogéneos, los ensambles de árboles con impulso del gradiente siguen siendo el punto de referencia práctico frente a arquitecturas neuronales. Las implementaciones basadas en histogramas agrupan los valores de cada variable en cubetas antes de buscar los cortes, lo que reduce el costo de entrenamiento de forma sustancial y las hace viables en millones de registros (Ke et al., 2017). En este trabajo se emplea `HistGradientBoostingClassifier` de `scikit-learn` (Pedregosa et al., 2011), que además maneja valores faltantes de forma nativa —propiedad relevante aquí, porque la codificación de ausencia de la base de la DGE resulta informativa, como documenta el apartado 3.3.1, y no conviene imputarla a ciegas.

El desbalance de clases se atiende reponderando la función de pérdida. Esa decisión tiene una consecuencia poco discutida: los puntajes resultantes dejan de ser probabilidades calibradas y sobreestiman el riesgo absoluto. La corrección estándar es una transformación monótona ajustada sobre datos no vistos, como la regresión isotónica (Zadrozny y Elkan, 2002). Por ser monótona, preserva el ordenamiento —y con él el AUROC— mientras corrige el nivel.

2.3.3 Criterios formales de equidad algorítmica

Sea A un atributo sensible, Y el desenlace observado, $\hat{Y}$ la predicción binaria y R el puntaje de riesgo. Las tres familias de criterios que se emplean en esta tesis corresponden a las tres relaciones de independencia posibles entre esas variables:

- **Paridad demográfica (independencia).** $P(\hat{Y} = 1 \mid A = a)$ constante en a . Iguala la tasa de selección entre grupos, sin condicionar al desenlace.
- **Equalized odds (separación).** $P(\hat{Y} = 1 \mid Y = y, A = a)$ constante en a para $y \in \{0, 1\}$; es decir, igualdad simultánea de sensibilidad y tasa de falsos positivos (Hardt et al., 2016). Su relajación a $y = 1$ —igualdad de oportunidades— es la que más importa clínicamente: significa que el modelo detecta a quien va a fallecer con la misma probabilidad en todos los grupos.
- **Calibración por grupo (suficiencia).** $P(Y = 1 \mid R = r, A = a)$ constante en a . Significa que un riesgo de 0.3 quiere decir lo mismo en cada entidad federativa.

2.3.4 El teorema de imposibilidad

Estos criterios no pueden satisfacerse a la vez. Cuando la prevalencia del desenlace difiere entre grupos y el clasificador no es perfecto, la calibración por grupo y equalized odds son mutuamente incompatibles (Chouldechova, 2017; Kleinberg et al., 2017). Es el resultado teórico más importante para este trabajo y conviene enunciar con precisión la forma que toma aquí.

Las tasas de mortalidad por entidad difieren en la cohorte por un factor de 5.6, como documenta el apartado 3.3.2. Sobre un puntaje bien calibrado, ningún conjunto de reglas de decisión puede igualar **a la vez** la sensibilidad y la tasa de falsos positivos entre entidades. Sí puede igualarse **una** de las dos: un umbral por grupo deja intacta la calibración —que es propiedad del puntaje y no de la regla— y permite escoger cuál de las dos tasas se reparte por igual, a costa de desigualar la otra.

La consecuencia práctica es la que estructura el entregable de la tesis. La elección entre criterios es normativa y no estadística; por eso el resultado adecuado no es un único modelo «justo», sino una frontera que explicita el intercambio y traslade la decisión a quien tiene la responsabilidad de tomarla.

2.3.5 Técnicas de mitigación del sesgo

Las técnicas se clasifican por la etapa del canal en la que intervienen, y cada familia tiene supuestos distintos sobre dónde reside el problema.

- **Pre-procesamiento.** Modifican los datos antes de entrenar: reponderación de muestras, remuestreo o corrección de representación. Son agnósticas al modelo, pero solo actúan sobre el desequilibrio de representación; suponen, por tanto, que la inequidad proviene de la composición de la muestra.
- **In-procesamiento.** Incorporan la restricción de equidad en la optimización. La reducción por gradiente exponenciado convierte el problema restringido en una secuencia de problemas ponderados y admite restricciones de equalized odds (Bird et al., 2020).
- **Post-procesamiento.** Ajustan la regla de decisión sobre un modelo ya entrenado, típicamente eligiendo un umbral por grupo (Hardt et al., 2016). Son las más eficaces cuando el problema no es el ordenamiento sino dónde se

corta, y las más controvertidas porque usan el atributo sensible en el momento de la decisión.

Un problema abierto especialmente pertinente aquí es la equidad de subgrupos pequeños: al desagregar por 32 entidades, los estados con menos registros producen estimaciones de sensibilidad con varianza alta, y los métodos que optimizan brechas máximas tienden a perseguir ruido. De ahí que el diseño incorpore un criterio explícito de soporte mínimo por grupo y procedimientos de cuantificación de la incertidumbre.

2.3.6 La frontera de Pareto como instrumento de decisión

El teorema de imposibilidad convierte la mitigación en un problema de compromiso, y el objeto teórico adecuado para representarlo es una frontera de Pareto: el conjunto de políticas de despliegue tales que no existe otra que mejore la equidad sin empeorar el desempeño, ni al contrario.

En el diseño de esta tesis, la frontera se traza interpolando linealmente entre el umbral global τ y el umbral específico de cada entidad τ_g , mediante $\tau_g(\alpha) = (1 - \alpha) \cdot \tau + \alpha \cdot \tau_g$, con $\alpha \in [0, 1]$. Cada valor de α define una política concreta: $\alpha = 0$ es el modelo sin mitigar y $\alpha = 1$ la corrección completa por entidad. El conjunto de pares (brecha de sensibilidad, desempeño global) es el instrumento entregable, porque traslada al responsable de la política una elección que es normativa y no técnica, en lugar de esconderla en un valor por omisión.

2.4 Marco conceptual

Este apartado fija el significado de los conceptos centrales del trabajo y su traducción a cantidades medibles. La distinción entre definición conceptual y definición operacional se mantiene de forma explícita, porque buena parte de la confusión en la literatura de equidad proviene de nombrar «sesgo» a cosas que se miden de maneras incompatibles.

2.4.1 Conceptos centrales

- **Estratificación de riesgo clínico.** Asignación de una probabilidad de desenlace adverso a cada paciente, con el fin de ordenar la atención. Se distingue del diagnóstico en que no afirma un estado presente, sino un curso probable.
- **Punto de predicción.** Momento del proceso de atención en el que el modelo emitiría su estimación. En este trabajo es el primer contacto. Es un concepto definitorio y no un detalle de implementación: fija qué información es admisible como predictor.
- **Fuga de información.** Uso como predictor de información que no está disponible en el punto de predicción. Produce un desempeño aparente que no se puede reproducir en despliegue.
- **Atributo sensible.** Variable respecto de la cual se exige que el comportamiento del modelo sea equitativo. En este trabajo, la entidad federativa de residencia; secundariamente, el sexo y el grupo etario.
- **Sesgo geográfico.** Diferencia sistemática en la calidad de las predicciones del modelo entre entidades federativas. No es la diferencia de riesgo entre entidades —que es un hecho epidemiológico— sino la diferencia en cuán bien el modelo estima ese riesgo.
- **Auditoría de equidad.** Evaluación del desempeño del modelo desagregado por los valores de un atributo sensible, con el fin de detectar disparidades.
- **Mitigación.** Intervención sobre los datos, el entrenamiento o la regla de decisión con el fin de reducir una disparidad medida.
- **Punto de operación.** Umbral de decisión sobre el puntaje de riesgo que convierte una probabilidad en una acción. Todas las métricas dependientes de umbral se reportan en un punto de operación único y declarado, para que las comparaciones entre etapas sean válidas.
- **Transportabilidad.** Grado en que el desempeño y la equidad de un modelo se conservan al aplicarlo a una población o fuente distinta de la de ajuste.

2.4.2 Variables del estudio

La tabla 2 resume las variables del estudio con su papel, tipo y definición operacional.

Tabla 2. Variables del estudio y sus definiciones operacionales.

Variable	Papel	Tipo	Definición operacional
defuncion	Dependiente	Binaria	1 si FECHA_DEF contiene una fecha válida; 0 si contiene el código 9999-99-99
EDAD	Independiente	Continua	Edad en años al momento del registro, acotada al intervalo [0, 120]
sexo_mujer	Independiente / sensible	Binaria	1 = mujer, 0 = hombre, derivada de SEXO; faltante si el código es 99
Once comorbilidades (_bin)	Independientes	Binarias	1 = sí, 0 = no, faltante para los códigos 97 a 99
entidad_nombre	Atributo sensible	Categórica (32)	Entidad de residencia (ENTIDAD_RES) traducida con el catálogo oficial; no se usa como predictor
grupo_edad	Atributo sensible	Categórica (4)	Cortes fijos en 0–17, 18–39, 40–59 y 60 o más años
hospitalizado	Auxiliar	Binaria	Derivada de TIPO_PACIENTE; solo para descripción y análisis de sensibilidad
Índice de marginación	Contextual	Continua	Índice CONAPO 2020 por entidad, unido por clave de entidad

2.4.3 Definiciones operacionales de las métricas

La tabla 3 traduce los conceptos anteriores a las cantidades que se calculan. Las métricas de equidad se implementan de forma explícita, y no se delegan a una biblioteca, para que el cálculo sea auditable línea por línea; son equivalentes a las definiciones de Fairlearn (Bird et al., 2020).

Tabla 3. Definiciones operacionales de las métricas por dimensión de evaluación.

Dimensión	Métrica	Definición operacional
Discriminación	AUROC	Área bajo la curva ROC sobre el conjunto de prueba
Discriminación	AUPRC	Área bajo la curva precisión–exhaustividad; se reporta junto con su razón respecto de la prevalencia, que es su línea base
Calibración	Puntaje de Brier	Error cuadrático medio entre probabilidad predicha y desenlace observado
Calibración	Error de calibración por grupo	Máxima diferencia absoluta, entre grupos, entre riesgo medio predicho y observado
Equidad	Brecha de sensibilidad	Diferencia entre la máxima y la mínima sensibilidad por grupo en el punto de operación (equalized odds)
Equidad	Brecha de tasa de falsos positivos	Diferencia entre la máxima y la mínima tasa de falsos positivos por grupo
Equidad	Brecha de AUROC	Diferencia entre el máximo y el mínimo AUROC por grupo
Equidad	Brecha de tasa de selección	Diferencia entre la máxima y la mínima proporción de casos marcados como de riesgo (paridad demográfica)
Interpretabilidad	Importancia por permutación	Caída del AUROC al permutar aleatoriamente cada variable
Utilidad agregada	Exactitud balanceada	Media de sensibilidad y especificidad en el punto de operación

Dos criterios operacionales complementan la tabla. **Soporte por grupo:** un grupo se considera evaluable si tiene al menos 500 observaciones y 20 casos positivos en el bloque correspondiente; por debajo de ese umbral, la varianza de la estimación domina cualquier señal de inequidad, y los grupos descartados se reportan de forma explícita en lugar de omitirse en silencio. **Incertidumbre:** las brechas se acompañan de intervalos de confianza por remuestreo estratificado por entidad y de una prueba de permutación sobre la etiqueta de grupo, porque la diferencia entre el máximo y el mínimo de 32 estimaciones ruidosas está sesgada al alza aun en ausencia de todo efecto.

Capítulo 3

Metodología



Capítulo 3. Metodología

Este capítulo documenta la metodología del trabajo empírico, y en particular la base de datos sobre la que se sostiene: de dónde provienen los datos, cómo se construyó la cohorte de análisis, qué variables se derivaron, qué transformaciones se aplicaron y qué muestra su exploración. El nivel de detalle es deliberado. En un trabajo cuyo objeto es auditar la equidad de un modelo, el proceso de captura del dato no es un preliminar técnico: es una fuente candidata de la inequidad que se pretende medir.

3.1 Fuente de datos y construcción de la cohorte

La construcción de la base persigue un requisito por encima de los demás: que el conjunto final contenga únicamente información disponible en el momento en que se tomaría la decisión clínica que el modelo pretende apoyar. Todo lo demás — volumen, riqueza de variables, comodidad de formato— está subordinado a ese requisito.

3.1.1 Fuentes de información

La **fuentes primaria** es la base abierta de COVID-19 de la Dirección General de Epidemiología (DGE) de la Secretaría de Salud (Dirección General de Epidemiología, 2022). Se emplea el corte anual COVID19MEXICO2021.csv, que contiene 8 830 345 registros de notificación del año 2021 con variables demográficas, entidad de residencia, comorbilidades y desenlaces. Es una fuente de notificación epidemiológica de cobertura nacional, publicada bajo los Términos de Libre Uso de la Información del Gobierno de México, sin identificadores personales directos.

Como **fuentes de contexto** se emplea el índice de marginación por entidad federativa de CONAPO, edición 2020, construido con el método de distancias ponderadas al cuadrado sobre el Censo de Población y Vivienda 2020 del INEGI (Consejo Nacional de Población, 2021). Se usa el archivo por entidad IME_2020.xls, del que se toman el índice y el grado de marginación. Su papel es examinar la

hipótesis H2, es decir, si la disparidad geográfica del modelo se asocia a la desigualdad estructural de la entidad.

Como **fuentes previstas para la validación externa** se identificó el Subsistema Automatizado de Egresos Hospitalarios de la DGIS (Dirección General de Información en Salud, 2024). Su explotación queda fuera del alcance de esta entrega y se reporta como trabajo pendiente.

3.1.2 Construcción de la cohorte y definición del desenlace

La cohorte de análisis se restringe a **casos COVID confirmados** ($\text{CLASIFICACION_FINAL} \in \{1, 2, 3\}$), lo que produce $n = 2\,526\,649$ registros con una mortalidad observada de 5.60 % y una tasa de hospitalización de 11.78 %.

La restricción es deliberada y no un detalle de filtrado. Un modelo de mortalidad **por COVID** debe estimarse sobre enfermos de COVID. Incluir casos negativos y sospechosos mezcla poblaciones con mecanismos de riesgo distintos y diluye la señal: la prevalencia del desenlace cae entonces a 2.06 % y el modelo pasa a describir mortalidad en población tamizada, que es otra pregunta. La diferencia entre 5.60 % y 2.06 % separa dos poblaciones con riesgo basal muy distinto.

El desenlace modelado es la **defunción**, derivada del campo FECHA_DEF : la base codifica 9999-99-99 para paciente vivo. En la cohorte hay 141 499 defunciones registradas.

La cohorte tiene una propiedad estructural que condiciona toda lectura posterior y conviene declarar aquí. Entre los casos confirmados, el número de defunciones registradas como ambulatorias es cero: fallecer implica estar registrado como hospitalizado. El desenlace solo es posible, por tanto, en el 11.8 % de la cohorte ($n = 297\,685$), y el resto son casos que no pueden fallecer por construcción. Esto no invalida la tarea —estimar riesgo al primer contacto sobre todo caso confirmado es precisamente el triage que motiva la tesis— pero significa que parte de la discriminación del modelo consistirá en separar ambulatorios de hospitalizados. El análisis de sensibilidad previsto cuantifica cuánta.

3.1.3 Creación y definición de nuevas variables

La base original codifica las categóricas con enteros y usa códigos especiales para la ausencia: 97 (no aplica), 98 (se ignora) y 99 (no especificado). El conjunto analítico se deriva del original mediante las siguientes construcciones.

- **defuncion.** Indicador binario derivado de FECHA_DEF (1 si existe fecha de defunción registrada). Es la variable objetivo.
- **hospitalizado.** Indicador binario derivado de TIPO_PACIENTE. Se usa para describir la cohorte y para el análisis de sensibilidad, **nunca** como predictor de mortalidad.
- **EDAD.** Se conserva en años; los valores fuera del intervalo [0, 120] se marcan como faltantes.
- **sexo_mujer.** Indicador binario (1 = mujer) derivado de SEXO, dejando faltante el código 99.
- **entidad_nombre.** ENTIDAD_RES se traduce a nombre mediante el catálogo oficial de 32 entidades; los códigos 97 a 99 quedan sin etiqueta. Esta es la variable que actúa como atributo sensible de la auditoría.
- **grupo_edad.** Variable categórica con cortes en 0–17, 18–39, 40–59 y 60 o más años, definida una única vez para todo el canal a fin de que los análisis por edad sean comparables entre etapas.
- **Once pares por comorbilidad.** Cada variable clínica —diabetes, EPOC, asma, inmunosupresión, hipertensión, otra comorbilidad, enfermedad cardiovascular, obesidad, enfermedad renal crónica, tabaquismo y neumonía— produce dos columnas: una binaria con sufijo _bin (1 = sí, 0 = no, faltante en otro caso) y un **indicador de faltante** con sufijo _na.

La decisión de conservar la ausencia como información, en lugar de imputarla a ciegas, merece justificarse porque no es la práctica habitual. Su frecuencia difiere entre entidades y su presencia se asocia al desenlace, de modo que la ausencia es en sí misma un posible mecanismo de inequidad geográfica; el apartado 3.3 lo documenta con cifras. El conjunto resultante tiene 31 columnas y se materializa en formato Parquet acompañado de un manifiesto que registra procedencia, número

de filas, esquema, tasas observadas y versiones de biblioteca, de modo que ninguna etapa posterior consuma un artefacto sin verificar su origen.

3.2 Preprocesamiento de los datos

El preprocesamiento comprende tres decisiones: qué variables se admiten como predictores, cómo se tratan los valores especiales y cómo se reparte la cohorte entre ajuste y evaluación.

3.2.1 Control de fuga de información

El control de fuga de información es la decisión metodológica más importante del canal. El punto de predicción es el **primer contacto**, de modo que ninguna variable posterior a ese momento puede ser predictor. Se excluyen explícitamente:

- **UCI** e **INTUBADO**, que describen el curso hospitalario y solo se conocen después de la decisión que el modelo pretende apoyar.
- **FECHA_DEF** y todo lo derivado de ella, salvo el desenlace mismo.
- **TIPO_PACIENTE** como predictor de mortalidad, por ser posterior al triage.

Los predictores admitidos son, por tanto, la edad, el sexo y once comorbilidades o signos registrados al primer contacto. Los indicadores de ausencia se conservan en el conjunto para el análisis descriptivo, pero no se emplean como predictores. La entidad federativa tampoco se incluye entre las entradas: se reserva como atributo sensible para auditar.

La inclusión de NEUMONIA merece justificación aparte. En el formato de la DGE se captura en el primer contacto y no durante la evolución hospitalaria, por lo que es admisible en ese punto. Aun así resulta el predictor más informativo del modelo, de modo que la validez de esa captura es un supuesto del que dependen los resultados. El análisis de sensibilidad reentrena el modelo sin ella para acotar cuánto del desempeño y de la inequidad descansan en esa única variable.

3.2.2 Limpieza y recodificación

Sobre las variables derivadas en el apartado 3.1.3 se aplica un tratamiento uniforme: los códigos 97 a 99 se convierten en faltante explícito y quedan registrados en el

indicador correspondiente; la edad se acota al intervalo plausible; y las categóricas se traducen a etiquetas legibles mediante los catálogos oficiales del diccionario de datos. No se aplica imputación. El modelo principal previsto maneja los valores faltantes de forma nativa, lo que evita introducir en los datos un supuesto que no se puede verificar.

3.2.3 Partición de datos

Se emplea una partición en tres bloques, estratificada por el desenlace y con semilla fija:

- **Prueba** (25 %, $n = 631\,663$). Se separa primero y no interviene en ninguna decisión de ajuste.
- **Calibración** (20 % del resto, $n = 378\,998$). Se usa exclusivamente para ajustar la transformación de calibración y los umbrales por grupo de la mitigación por post-procesamiento.
- **Entrenamiento** (el remanente, $n = 1\,515\,988$). Ajuste de los modelos.

El tercer bloque es necesario, y no un refinamiento cosmético. Tanto la calibración como los umbrales por entidad son parámetros ajustados a datos; si se estiman sobre el conjunto de prueba, las métricas resultantes están sesgadas optimistamente. Separar el bloque de calibración es lo que permite después cuantificar ese optimismo en lugar de heredarlo.

3.3 Análisis exploratorio de los datos

La exploración persigue dos objetivos: verificar que la calidad del dato admite el análisis propuesto y caracterizar la heterogeneidad que motiva la pregunta de investigación.

3.3.1 Calidad del dato y estructura de la ausencia

La calidad es alta en las variables clave: la edad tiene 0.0013 % de valores faltantes, y el sexo y la entidad de residencia están completos. En las comorbilidades, la proporción de códigos de ausencia oscila entre 0.17 % y 0.88 %, con el máximo en OTRA_COM.

Esa ausencia **no es ruido aleatorio**, lo que justifica conservarla en lugar de imputarla. En nueve de las once comorbilidades, los registros con código de ausencia tienen una mortalidad hasta 2.2 veces mayor que los que sí están codificados: en EPOC, 12.5 % frente a 5.6 %. En NEUMONIA la relación se invierte por completo (razón 0.017), lo que es coherente con que sea el predictor dominante: no registrar neumonía acompaña a los casos leves.

Más relevante para el eje de este trabajo es que la frecuencia de la ausencia difiere enormemente entre estados: la máxima proporción de faltantes por entidad va de 0.02 % en Quintana Roo a 5.55 % en el Estado de México, un factor cercano a 280. La calidad del registro clínico es, por tanto, desigual entre entidades, y constituye un mecanismo plausible de inequidad geográfica que este trabajo documenta pero no explota: los indicadores de ausencia no se usan como predictores. La tabla 4 resume la estructura de esa ausencia variable por variable.

Tabla 4. Estructura de la ausencia en las variables clínicas de la cohorte.

Variable	Ausencia (%)	Mortalidad con ausencia (%)	Mortalidad sin ausencia (%)	Razón
EPOC	0.18	12.47	5.59	2.23
CARDIOVASCULAR	0.18	12.47	5.59	2.23
TABAQUISMO	0.18	12.28	5.59	2.20
RENAL_CRONICA	0.18	12.22	5.59	2.19
ASMA	0.17	11.87	5.59	2.12
INMUSUPR	0.18	11.78	5.59	2.11
HIPERTENSION	0.18	11.44	5.59	2.05
DIABETES	0.19	11.42	5.59	2.04
OBESIDAD	0.17	11.03	5.59	1.97
OTRA_COM	0.88	5.45	5.60	0.97
NEUMONIA	0.57	0.10	5.63	0.02

3.3.2 Heterogeneidad entre entidades federativas

La figura 1 muestra la heterogeneidad que motiva la tesis. El tamaño de muestra por entidad varía por un factor de 43 —de 15 221 a 651 956 registros— y las tasas de defunción difieren por un factor de 5.6 entre los extremos.




Figura 1. Heterogeneidad entre entidades federativas en la cohorte: tasa de defunción (izquierda) y tamaño de muestra (derecha).

Esa doble heterogeneidad —de volumen y de riesgo basal— es exactamente la condición de la que cabe esperar un desempeño desigual, y por dos mecanismos distintos que conviene no confundir. El desequilibrio de volumen implica que el ajuste está dominado por unas pocas entidades grandes. La diferencia de prevalencia implica, además, que un umbral de decisión único no puede significar lo mismo en todas ellas; el apartado 2.3 formaliza por qué esto último no es un defecto corregible del modelo, sino una imposibilidad matemática.

3.3.3 Distribución del riesgo y del desenlace

La figura 2 resume la distribución de las variables predictoras y su relación con el desenlace. Tres rasgos orientan el modelado. Primero, el desbalance de clases es de 16.9 a 1, lo que obliga a reponderar la función de pérdida y —como consecuencia— a recalibrar después el puntaje. Segundo, la mortalidad crece de forma marcadamente monótona con la edad, desde 0.29 % en el grupo más joven hasta 25.6 % en el de 60 años o más, un gradiente de casi dos órdenes de magnitud que anticipa que la edad concentrará buena parte de la señal. Tercero, la prevalencia de las comorbilidades registradas es moderada, de modo que su aporte marginal por encima de la edad y la neumonía es limitado.




Figura 2. Análisis exploratorio de la cohorte 2021: distribución de las variables predictoras y su relación con el desenlace.

El gradiente por edad tiene una consecuencia para la auditoría que conviene anticipar. Si la composición etaria difiere entre entidades, parte de cualquier disparidad geográfica observada podría no ser geográfica en absoluto, sino un efecto de edad mal atribuido. Por eso el diseño de la auditoría incluye la restricción del análisis al subgrupo de 60 años o más: es la comprobación mínima para distinguir una explicación de la otra.

Conclusiones y recomendaciones

Conclusiones y recomendaciones

Este documento corresponde a la primera entrega del proyecto terminal y cubre el análisis y desarrollo conceptual: la introducción con el planteamiento del problema, el marco teórico y la metodología con la construcción y caracterización de la base de datos. Las conclusiones que siguen son, por tanto, parciales, y se refieren a lo que estas tres etapas permiten ya afirmar.

Sobre el planteamiento. La revisión del estado del arte confirma que el vacío que motiva el trabajo existe y no es una suposición: la predicción de desenlaces por COVID-19 con datos mexicanos converge en un techo de desempeño, la geografía se ha estudiado como predictor y no como eje de equidad, y la literatura de equidad algorítmica en salud está anclada en otros países y otros atributos sensibles. La pregunta de si un modelo clínico entrenado con datos mexicanos es igual de preciso entre entidades federativas permanece sin responder.

Sobre la metodología y la base de datos. La cohorte construida es viable para el análisis propuesto: 2 526 649 casos confirmados con una mortalidad observada de 5.60 % y una calidad alta en las variables clave. La exploración documenta además las dos condiciones de las que cabe esperar inequidad: el tamaño de muestra por entidad varía por un factor de 43 y las tasas de defunción por un factor de 5.6. Un tercer hallazgo, no previsto, es que la calidad del registro clínico es también desigual entre entidades —la proporción de códigos de ausencia va de 0.02 % a 5.55 %—, lo que constituye un mecanismo candidato de inequidad que el trabajo documenta pero deliberadamente no explota.

Sobre el marco teórico. El teorema de imposibilidad, combinado con el factor de 5.6 entre las tasas de mortalidad por entidad, permite anticipar un resultado antes de ajustar cualquier modelo: sobre un puntaje calibrado no existirá ninguna regla de decisión que iguale simultáneamente la sensibilidad y la tasa de falsos positivos entre entidades. Esa imposibilidad no es un obstáculo del método, sino la razón por la que el entregable de la tesis debe ser una frontera de compromiso y no un modelo único.

Recomendaciones para la etapa siguiente. Tres decisiones quedan fijadas por lo anterior. Primera, la auditoría debe realizarse sobre el puntaje calibrado, porque

sobre el puntaje crudo el error de calibración por grupo mide el sesgo global de entrenamiento y no la inequidad. Segunda, toda métrica dependiente de umbral debe reportarse en un punto de operación único y declarado, para que las comparaciones entre etapas sean válidas. Tercera, las brechas deben acompañarse de una medida de incertidumbre, porque con 32 grupos de tamaño muy desigual el estadístico de brecha máxima está sesgado al alza. Queda pendiente, y así se reporta, la validación externa sobre una fuente independiente, que es la que sustentaría la hipótesis H4.

Fuentes de consulta

- Becerra-Sánchez, A., Rodarte-Rodríguez, A., Escalante-García, N. I., Olvera-González, J. E., De la Rosa-Vargas, J. I., Zepeda-Valles, G., y Velásquez-Martínez, E. de J. (2022). Mortality analysis of patients with COVID-19 in Mexico based on risk factors applying machine learning techniques. *Diagnostics*, 12(6), 1396. <https://doi.org/10.3390/diagnostics12061396>
- Bird, S., Dudík, M., Edgar, R., Horn, B., Lutz, R., Milan, V., Sameki, M., Wallach, H., y Walker, K. (2020). Fairlearn: A toolkit for assessing and improving fairness in AI (Informe técnico MSR-TR-2020-32). Microsoft Research. <https://www.microsoft.com/en-us/research/publication/fairlearn-a-toolkit-for-assessing-and-improving-fairness-in-ai/>
- Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2), 153–163. <https://doi.org/10.1089/big.2016.0047>
- Collins, G. S., Reitsma, J. B., Altman, D. G., y Moons, K. G. M. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): The TRIPOD statement. *Annals of Internal Medicine*, 162(1), 55–63. <https://doi.org/10.7326/M14-0697>
- Consejo Nacional de Población. (2021). Índices de marginación 2020. Gobierno de México. <https://www.gob.mx/conapo/documentos/indices-de-marginacion-2020-284372>
- Dirección General de Epidemiología. (2022). Datos abiertos de COVID-19. Secretaría de Salud, Gobierno de México. <https://www.gob.mx/salud/documentos/datos-abiertos-152127>
- Dirección General de Información en Salud. (2024). Subsistema Automatizado de Egresos Hospitalarios (series 2008–2024). Secretaría de Salud, Gobierno de México.

- Hardt, M., Price, E., y Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* 29 (pp. 3315–3323). Curran Associates.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., y Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems* 30 (pp. 3146–3154). Curran Associates.
- Kleinberg, J., Mullainathan, S., y Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. En *8th Innovations in Theoretical Computer Science Conference (ITCS 2017)* (Vol. 67, pp. 43:1–43:23). Schloss Dagstuhl–Leibniz-Zentrum für Informatik.
<https://doi.org/10.4230/LIPIcs.ITCS.2017.43>
- Maldonado-Sifuentes, C. E., Vargas-Santiago, M., Leon-Velasco, D. A., Ortega-García, M. C., Ledo-Mezquita, Y., y Castillo-Velasquez, F. A. (2024). Leveraging machine learning to unveil the critical role of geographic factors in COVID-19 mortality in Mexico. *Computación y Sistemas*, 28(1), 5–18.
<https://doi.org/10.13053/CyS-28-1-4908>
- Méndez-Astudillo, J. (2024). The impact of comorbidities and economic inequality on COVID-19 mortality in Mexico: A machine learning approach. *Frontiers in Big Data*, 7, 1298029. <https://doi.org/10.3389/fdata.2024.1298029>
- Nejadshamsi, S., H. Chu, C., McGilton, K. S., Li, X., Ronquillo, C., y Abbasgholizadeh-Rahimi, S. (2026). Evaluation and improvement of algorithmic fairness for COVID-19 severity classification using explainable artificial intelligence-based bias mitigation. *JAMIA Open*, 9(1), ooaf171.
<https://doi.org/10.1093/jamiaopen/ooaf171>
- Obermeyer, Z., Powers, B., Vogeli, C., y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464), 447–453. <https://doi.org/10.1126/science.aax2342>

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Ricci Lara, M. A., Echeveste, R., y Ferrante, E. (2022). Addressing fairness in artificial intelligence for medical imaging. *Nature Communications*, 13(1), 4581. <https://doi.org/10.1038/s41467-022-32186-3>
- Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., y Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. *BMC Medicine*, 17(1), 230. <https://doi.org/10.1186/s12916-019-1466-7>
- Vickers, A. J., y Elkin, E. B. (2006). Decision curve analysis: A novel method for evaluating prediction models. *Medical Decision Making*, 26(6), 565–574. <https://doi.org/10.1177/0272989X06295361>
- Wynants, L., Van Calster, B., Collins, G. S., Riley, R. D., Heinze, G., Schuit, E., Albu, E., Arshi, B., Bellou, V., Bonten, M. M. J., Dahly, D. L., Damen, J. A., Debray, T. P. A., ... van Smeden, M. (2020). Prediction models for diagnosis and prognosis of covid-19: Systematic review and critical appraisal. *BMJ*, 369, m1328. <https://doi.org/10.1136/bmj.m1328>
- Zadrozny, B., y Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. En *Proceedings of the eighth ACM SIGKDD international conference on Knowledge discovery and data mining* (pp. 694–699). ACM. <https://doi.org/10.1145/775047.775151>

ANEXOS

ANEXO 1

Variables admitidas y excluidas del modelo

Este anexo detalla el resultado del control de fuga de información descrito en el apartado 3.2.1. La columna «Disponible al primer contacto» es el criterio de admisión: una variable solo puede ser predictor si su valor se conoce en el momento en que el modelo emitiría su estimación.

Tabla 5. Variables de la base de la DGE y su tratamiento en el estudio.

Variable original	Disponible al primer contacto	Papel en el estudio	Motivo
EDAD	Sí	Predictor	Registrada en la notificación inicial
SEXO	Sí	Predictor y atributo sensible	Registrada en la notificación inicial
DIABETES	Sí	Predictor	Comorbilidad interrogada al primer contacto
EPOC	Sí	Predictor	Comorbilidad interrogada al primer

Variable original	Disponible al primer contacto	Papel en el estudio	Motivo
			contacto
ASMA	Sí	Predictor	Comorbilidad interrogada al primer contacto
INMUSUPR	Sí	Predictor	Comorbilidad interrogada al primer contacto
HIPERTENSION	Sí	Predictor	Comorbilidad interrogada al primer contacto
OTRA_COM	Sí	Predictor	Comorbilidad interrogada al primer contacto
CARDIOVASCULAR	Sí	Predictor	Comorbilidad interrogada al primer contacto
OBESIDAD	Sí	Predictor	Comorbilidad interrogada al primer contacto
RENAL_CRONICA	Sí	Predictor	Comorbilidad interrogada al primer

Variable original	Disponible al primer contacto	Papel en el estudio	Motivo
			ada al primer contacto
TABAQUISMO	Sí	Predic tor	Comorb ilidad interrog ada al primer contacto
NEUMONIA	Sí (supuesto declarado)	Predic tor	Se captura en el formato inicial; se somete a análisis de sensibilidad por ser el predictor dominante
ENTIDAD_RE S	Sí	Atributo sensible, no predictor	Se reserva como eje de auditoría; incluirla como entrada impediría medir la inequidad que se busca
CLASIFICACION_FINAL	Sí	Criterio de inclusión	Define la cohorte de casos confirmados

Variable original	Disponible al primer contacto	Papel en el estudio	Motivo
FECHA_DEF	No	Desenlace	Posterior al punto de predicción; solo se usa para derivar la variable objetivo
TIPO_PACIENTE	No	Excluida como predictor	Posterior al triage; se usa solo para describir y para el análisis de sensibilidad
UCI	No	Excluida	Describe el curso hospitalario
INTUBADO	No	Excluida	Describe el curso hospitalario; su uso como predictor constituiría fuga de información

El resultado es un conjunto de trece predictores: edad, sexo y once comorbilidades o signos registrados al

primer contacto. Los indicadores de ausencia derivados de esas mismas variables se conservan en el conjunto

para el análisis descriptivo del apartado 3.3.1, pero no se emplean como entradas del modelo.