
Estratificación de riesgo clínico consciente de la equidad

Auditoría y mitigación del sesgo geográfico entre entidades federativas
en modelos predictivos con datos abiertos de salud de México

David Segundo García

Proyecto terminal · Maestría en Ciencia de Datos e Información
Asesor: Dr. Daniel Alejandro Cervantes Cabrera

Segunda entrega · Septiembre de 2026

Por qué este tema

Lo que ya está hecho

- Predecir mortalidad por COVID-19 con datos mexicanos ha sido **ampliamente estudiado**.
- Los trabajos revisados convergen en niveles de desempeño similares.

Lo que no


- Si ese desempeño es **el mismo en todo el país**.
- En la literatura revisada no se identificaron trabajos que traten la **entidad federativa** como atributo sensible.

Por qué importa en México

La organización federal de los servicios de salud hace que la entidad no sea una variable demográfica cualquiera: es la unidad en la que se **decide, se financia y se opera** la atención.

Un atributo sensible que coincide con la unidad administrativa de decisión tiene una propiedad poco común: **la corrección es implementable**.

El sesgo algorítmico en salud no es hipotético



Obermeyer et al. (2019), *Science*

Lección 1

El modelo **no usaba la raza**. Omitir el atributo sensible no garantiza equidad.

Lección 2

El sesgo estaba en la **definición del desenlace**, no en el algoritmo.

Planteamiento del problema

- Un modelo puede tener **excelente desempeño promedio** y, al mismo tiempo, ser sistemáticamente menos preciso para habitantes de entidades con menor infraestructura.
- Entrenado con datos dominados por entidades urbanas, puede desempeñarse peor **justo donde el sistema de salud es más débil**: amplifica la inequidad en lugar de reducirla.

Medir la inequidad del modelo y corregirla
—especialmente la geográfica—
sin sacrificar su utilidad clínica.

El objeto de estudio se desplaza: del acierto del modelo, a la *distribución* de sus errores entre grupos de población.

Preguntas de investigación y objetivos

Preguntas

- P1** ¿Hay disparidades entre **entidades**, edades y sexos?
- P2** ¿Se asocian al grado de **marginación**?
- P3** ¿Qué mitigación funciona, y a **qué costo**?
- P4** ¿Se conservan en una **fuentes distintas**?
- P5** ¿Hay inequidades **interseccionales**?

Objetivo general

Desarrollar un modelo de estratificación de riesgo, **auditar su equidad** —evaluar su desempeño por separado en cada grupo— y **mitigar** las disparidades encontradas.

Cinco objetivos específicos, del flujo reproducible con control de fuga de información hasta las recomendaciones de despliegue.

Cuatro hipótesis, que se contrastan al final.

Antecedentes y estado del arte

Tres tradiciones que avanzaron por separado: la **predicción con datos mexicanos**, la **epidemiología espacial** y la **equidad algorítmica en salud**. El problema pertenece al ámbito donde se cruzan.

Dimensión	En la literatura	Aporte de esta tesis
Predicción del desenlace (México)	Ampliamente estudiada	Línea de base, no aportación
Geografía como predictor (México)	Estudiada	Se distingue: geografía como <i>eje de equidad</i>
Equidad algorítmica en salud	Madura, fuera de México	Se traslada al contexto mexicano
Auditoría de equidad por entidad	No identificada en la revisión	Eje central del trabajo
Mitigación y frontera de Pareto	No identificada en la revisión	Instrumento de decisión entregable

Que la entidad *prediga* la mortalidad no dice nada sobre si el modelo es *igualmente confiable* en cada entidad.

Bases teóricas: dos propiedades que se confunden

Discriminación

¿Ordena bien a los pacientes por riesgo? Se resume en el AUROC.

Depende **solo del orden**, no del valor del puntaje.

Calibración

De cada cien pacientes con riesgo estimado de 20 %, ¿fallecen veinte?

La auditoría se hace sobre el puntaje calibrado.

Criterios formales de equidad

- **Independencia** — igual tasa de selección entre grupos.
- **Separación** — igual sensibilidad y tasa de falsos positivos (*equalized odds*, Hardt et al., 2016).
- **Suficiencia** — un riesgo de 0.3 significa lo mismo en cada entidad.

Sin calibrar, el error por grupo mide el sesgo global de entrenamiento y no la inequidad: en este trabajo, **0.2108** frente a **0.0231**.

El resultado teórico central: imposibilidad

Si la **prevalencia difiere** entre grupos y el clasificador **no es perfecto**, la calibración por grupo y la separación **no pueden cumplirse a la vez**.

Chouldechova (2017); Kleinberg et al. (2017)

Las dos condiciones se cumplen aquí

- Las tasas de mortalidad por entidad difieren por un factor de **5.6**.
- Ningún modelo de riesgo clínico acierta siempre.

Consecuencia práctica

- La calibración es propiedad del **puntaje**; la sensibilidad y el FPR, de la **regla de decisión**.
- Un umbral por entidad **no altera** la calibración y permite elegir *cuál* de las dos tasas se iguala.

Es un teorema demostrado: se aplica por deducción, no depende de los resultados empíricos.

Del teorema al entregable: la frontera de Pareto

- Si los criterios no pueden cumplirse a la vez, el resultado adecuado **no es un único modelo «justo»**.
- Cada política de despliegue produce un par: *disparidad y desempeño*.
- La frontera reúne las políticas donde ya no se puede mejorar una sin empeorar la otra.
- Se traza interpolando entre el umbral global y el umbral por entidad:


$$\tau_g(\alpha) = (1 - \alpha) \tau + \alpha \tau_g, \quad \alpha \in [0, 1]$$

Por qué importa

La elección entre políticas es **normativa, no técnica**.

El entregable traslada esa decisión a quien autoriza el despliegue, con **el costo de cada opción medido**, en lugar de esconderla en un valor por omisión.

Marco metodológico: CRISP-DM con una adaptación



La adaptación

Primero el desempeño **global**; después el desempeño **desagregado** por grupo. El segundo nivel puede devolver el proyecto al modelado *sin que el primero detecte problema alguno*.

Por qué CRISP-DM


Cubre el ciclo completo —a diferencia de SEMMA— y es independiente de la herramienta. Su límite conocido: no contempla la equidad, y por eso se adapta.

Avances: los datos y el hallazgo principal

Base abierta de la DGE, corte 2021, casos confirmados: **2 526 649** registros, mortalidad **5.60 %**. Punto de predicción: primer contacto. La entidad se **excluye** como entrada.

Aprueba todos los criterios agregados

AUROC **0.9503** · sensibilidad **79.5 %** · error de calibración **0.0231**.



Desempeño desagregado por entidad federativa.

Eje auditado	Brecha de sensibilidad
Entidad federativa (32)	0.2935
Sexo (2)	0.0393
Grupo etario (4)	0.5824

IC [0.267, 0.354] · permutación $p = 0.001$

Las hipótesis y lo que queda pendiente

	Enunciado	Resultado
H1	Un modelo con buen desempeño global presentará disparidades entre entidades	Sostenida (29.4 puntos)
H2	La disparidad se asociará a la marginación de la entidad	No sostenida ($r = -0.178$, $p = 0.328$)
H3	La mitigación reducirá la brecha con pérdida acotada	Sostenida ($0.294 \rightarrow 0.140$, sin costo)
H4	El desempeño se transferirá a una fuente independiente	Pendiente de validación externa

La limitación que condiciona todo lo demás

Restringido a pacientes hospitalizados, el AUROC cae de **0.9503** a **0.7001**: parte del desempeño aparente consistía en separar ambulatorios de hospitalizados.

Gracias

Un modelo puede acertar en promedio y fallar de forma sistemática en una parte del país.

Medirlo antes de desplegarlo es una decisión de método, no de oportunidad.

David Segundo García

Maestría en Ciencia de Datos e Información · INFOTEC

Asesor: Dr. Daniel Alejandro Cervantes Cabrera

