

INFOTEC

Centro de Investigación e Innovación
en Tecnologías de la Información y Comunicación

MAESTRÍA EN CIENCIA DE DATOS E INFORMACIÓN

Estratificación de riesgo clínico consciente de la equidad

Auditoría y mitigación del sesgo geográfico entre entidades federativas en
modelos predictivos con datos abiertos de salud de México

TESIS

que para obtener el grado de

Maestro en Ciencia de Datos e Información

presenta

David Segundo García

Asesor

Dr. Daniel Alejandro Cervantes Cabrera

31 de julio de 2026

Resumen

Existe una literatura amplia que predice hospitalización y mortalidad por COVID-19 con datos mexicanos, y su desempeño puede considerarse un problema resuelto. Esta tesis desplaza el objeto de estudio: no pregunta si un modelo acierta, sino *si acierta por igual*, con énfasis en el sesgo geográfico entre entidades federativas, una dimensión asociada a la desigualdad estructural del sistema de salud en México y prácticamente inexplorada.

Sobre la base abierta de COVID-19 de la Dirección General de Epidemiología (DGE), restringida a casos confirmados del año 2021 ($n = 2\,526\,649$; mortalidad observada 5.60 %), se entrena un modelo de referencia de mortalidad al primer contacto, con control estricto de fuga de información, y se calibra mediante regresión isotónica sobre un bloque de calibración independiente. El modelo alcanza un AUROC de 0.9503 y un puntaje de Brier de 0.0323 tras calibrar (frente a 0.0866 sin calibrar). Ese modelo se somete después a una auditoría de equidad por entidad, sexo y grupo etario, y a las tres familias de mitigación de sesgo –pre, in y post-procesamiento– sobre un punto de operación clínico común de 80 % de sensibilidad.

Los resultados confirman inequidad geográfica sustantiva: la sensibilidad varía 0.2935 entre entidades y el AUROC 0.0563, con el peor desempeño en Chihuahua (AUROC 0.9207) y el mejor en Tabasco (0.9770). La brecha persiste al restringir el análisis a adultos de 60 años o más, lo que descarta que se explique solo por composición etaria. En cambio, *no* se explica por la marginación de la entidad: el índice de CONAPO 2020 no muestra asociación con el desempeño ($r = -0.071$, $p = 0.700$) ni aparece gradiente al agregar por grado de marginación. Entre las intervenciones evaluadas, únicamente el post-procesamiento por umbrales específicos de entidad reduce la disparidad de forma apreciable –de 0.294 a 0.140, una reducción de 52 %– y lo hace sin costo de desempeño global. La reponderación previa al entrenamiento y la restricción de *equalized odds* durante el entrenamiento resultan insuficientes o inestables con 32 grupos de tamaño muy desigual. Documentar esa asimetría entre familias de mitigación es, en sí, un resultado.

Dos análisis de robustez acotan la lectura. Al excluir por completo una entidad del entrenamiento y evaluarla, el desempeño apenas cambia (pérdida mediana de AUROC

-0.0006) y las brechas no se acentúan: la inequidad no proviene de la cobertura de datos. Y al restringir la cohorte a los pacientes hospitalizados –la población en la que el desenlace es posible, pues fallecer implica estar registrado como hospitalizado– el AUROC cae a 0.7001 y la disparidad se desplaza del umbral hacia el ordenamiento, lo que sugiere que la mitigación por umbrales sería insuficiente en la población clínicamente crítica.

La contribución es la primera auditoría de equidad geográfica de un modelo clínico sobre datos abiertos mexicanos, acompañada de una frontera de Pareto equidad–desempeño utilizable como instrumento de decisión antes del despliegue.

Palabras clave: equidad algorítmica, sesgo geográfico, estratificación de riesgo, COVID-19, datos abiertos de salud, calibración, *equalized odds*, frontera de Pareto.

Índice general

Resumen	i
1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Preguntas de investigación	2
1.3. Objetivos	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.4. Hipótesis	3
1.5. Contribuciones	3
1.6. Alcance y delimitaciones	4
2. Marco teórico y trabajos relacionados	5
2.1. Modelos de riesgo clínico y su evaluación	5
2.2. Aprendizaje automático sobre datos tabulares	6
2.3. Equidad algorítmica	6
2.3.1. Definiciones	6
2.3.2. El teorema de imposibilidad	7
2.3.3. Mitigación	7
2.4. Trabajos relacionados y vacío de investigación	8
2.4.1. La parte predictiva mexicana está saturada	8
2.4.2. Lo geográfico ya se estudió, pero como predictor	8
2.4.3. La equidad algorítmica en salud es madura, pero fuera de México	9
2.4.4. El vacío que ocupa esta tesis	9
3. Metodología	10
3.1. Fuente de datos y cohorte	10
3.2. Definición de desenlaces y control de fuga de información	10

3.3.	Limpieza y recodificación	11
3.4.	Partición de datos	12
3.5.	Modelo de referencia	12
3.5.1.	Calibración	13
3.5.2.	Punto de operación	13
3.6.	Métricas	13
3.6.1.	Criterio de soporte por grupo	14
3.7.	Estrategias de mitigación	14
3.7.1.	Frontera de Pareto	15
3.8.	Análisis de sensibilidad: subconjunto hospitalizado	15
3.9.	Cuantificación de la incertidumbre	16
3.10.	Transportabilidad geográfica interna	16
3.11.	Reproducibilidad	17
4.	Resultados	18
4.1.	Caracterización de la cohorte	18
4.2.	Desempeño del modelo de referencia	19
4.2.1.	Efecto de la calibración	19
4.2.2.	Importancia de variables	20
4.3.	Auditoría de equidad	21
4.3.1.	Entidad federativa	21
4.3.2.	Incertidumbre de las brechas	23
4.3.3.	Sexo y grupo etario	25
4.3.4.	Análisis interseccional	26
4.3.5.	Correlatos de la inequidad geográfica	27
4.4.	Sensibilidad: la población en la que el desenlace es posible	28
4.4.1.	Efecto sobre el diagnóstico de equidad	29
4.4.2.	¿Depende el resultado de una sola variable?	29
4.5.	Transportabilidad geográfica interna	30
4.6.	Mitigación de sesgo	32
4.6.1.	Pre-procesamiento	32
4.6.2.	In-procesamiento	32
4.6.3.	Post-procesamiento	33
4.6.4.	Frontera de Pareto	33

5. Discusión	36
5.1. Evaluación de las hipótesis	36
5.2. Asimetría entre familias de mitigación	38
5.3. Implicaciones para el despliegue	39
5.4. Relación con la literatura	40
5.5. Limitaciones	41
6. Conclusiones y trabajo futuro	42
6.1. Conclusiones	42
6.2. Trabajo futuro	43
Referencias	45
A. Reproducibilidad del canal analítico	48
A.1. Estructura y orden de ejecución	48
A.2. Contrato de datos entre etapas	48
A.3. Determinismo	50
A.4. Entorno de ejecución	50
A.5. Reproducción del documento	51
B. Variables y codificación	52
B.1. Codificación de la fuente	52
B.2. Variables derivadas	52
B.3. Predictores admitidos y variables excluidas	52

Índice de tablas

2.1. Posición de esta tesis respecto de la literatura.	9
3.1. Métricas empleadas por dimensión de evaluación.	14
4.1. Importancia por permutación sobre el AUROC en el conjunto de prueba (3 repeticiones, submuestra de 50 000 observaciones).	20
4.2. Brechas máximas entre grupos por eje de auditoría, al umbral $\tau = 0.1562$. La brecha de TPR corresponde a la violación de <i>equalized odds</i> ; el error de calibración se mide sobre el riesgo calibrado.	21
4.3. Desempeño y equidad por entidad federativa en el conjunto de prueba ($n = 631\,663$), al umbral de sensibilidad objetivo $\tau = 0.1562$. Ordenadas por AUROC ascendente.	21
4.4. Desempeño por entidad con intervalos de confianza al 95 % obtenidos por remuestreo estratificado (1000 réplicas); cinco peores y cinco mejores por AUROC.	23
4.5. Prueba de permutación sobre las brechas entre entidades (1000 permutaciones de las etiquetas de entidad, conservando los tamaños de grupo). La brecha bajo la nula no es cero: con 32 grupos, máximo y mínimo se separan por azar.	24
4.6. Desempeño y equidad por sexo en el conjunto de prueba.	25
4.7. Desempeño y equidad por grupo etario en el conjunto de prueba.	26
4.8. Subgrupo interseccional: adultos de 60 años o más, por entidad (cinco peores y cinco mejores de 32 evaluadas). El deterioro persiste tras controlar por edad avanzada.	26
4.9. Desempeño medio por grado de marginación (CONAPO 2020), de mayor a menor carencia. Kruskal–Wallis sobre el AUROC entre grados: $H = 1.827$, $p = 0.768$	28
4.10. Análisis de sensibilidad: cohorte completa frente al subconjunto hospitalizado, que es donde el desenlace es posible. El AUPRC se acompaña de su razón respecto de la prevalencia, que es su línea base.	29

4.11. Transportabilidad geográfica interna: AUROC de cada entidad cuando participó en el entrenamiento frente a cuando fue excluida por completo (seis mayores pérdidas y cuatro mayores ganancias de 32 entidades).	30
4.12. Comparación de las tres familias de mitigación sobre el conjunto de prueba. Menor ΔTPR indica mayor equidad entre entidades.	32
4.13. Frontera de Pareto equidad–desempeño. El parámetro α interpola entre el umbral global ($\alpha = 0$) y el umbral por entidad estimado fuera de muestra ($\alpha = 1$). Cada fila es una política de despliegue posible.	34
A.1. Artefactos del canal analítico.	49
A.2. Versiones utilizadas para producir los resultados de este documento.	50
B.1. Códigos de la fuente relevantes para este trabajo.	52
B.2. Variables construidas y su papel en el análisis.	53

Índice de figuras

4.1. Heterogeneidad entre entidades federativas en la cohorte: tasa de defunción (izquierda) y tamaño de muestra (derecha).	19
4.2. Auditoría por entidad federativa: sensibilidad frente al objetivo global (izquierda), AUROC (centro) y calibración, riesgo medio predicho frente a mortalidad observada (derecha).	23
4.3. Izquierda: AUROC por entidad con intervalo de confianza al 95 %. Derecha: distribución de la brecha de AUROC bajo la hipótesis nula de ausencia de efecto de entidad, frente a la brecha observada.	24
4.4. Transportabilidad geográfica interna. Izquierda: AUROC por entidad habiendo participado en el entrenamiento frente a haber sido excluida. Derecha: pérdida frente al tamaño de la entidad.	31
4.5. Frontera de Pareto equidad–desempeño (izquierda) y desempeño por entidad frente al índice de marginación de CONAPO 2020 (derecha; un valor más alto indica menor marginación).	34

Capítulo 1

Introducción

1.1. Planteamiento del problema

La saturación hospitalaria y la asignación de recursos escasos son retos persistentes del sistema de salud mexicano. Contar con herramientas que estimen tempranamente el riesgo de un desenlace grave permite priorizar la atención y anticipar necesidades de camas y ventiladores. La literatura reciente muestra, sin embargo, que el problema puramente predictivo ya está ampliamente resuelto para el caso mexicano: existen múltiples modelos con buen desempeño (Becerra-Sánchez et al., 2022; Méndez-Astudillo, 2024).

El problema no abordado es otro. Un modelo puede tener excelente desempeño promedio y, al mismo tiempo, ser sistemáticamente menos preciso para habitantes de entidades con menor infraestructura, para personas mayores o para un sexo determinado. Esta posibilidad no es hipotética: el caso mejor documentado de sesgo algorítmico en salud es un modelo de gestión poblacional en Estados Unidos que asignaba menos recursos a pacientes afroamericanos con igual carga de enfermedad, no por usar la raza como predictor, sino porque el desenlace elegido –el gasto sanitario– estaba ya distorsionado por el acceso desigual (Obermeyer et al., 2019).

En un país tan heterogéneo como México, un modelo entrenado con datos dominados por entidades urbanas puede desempeñarse peor justo donde el sistema de salud es más débil, amplificando la inequidad en lugar de reducirla. El problema central de esta tesis es, por tanto, diagnosticar y corregir la inequidad del modelo –especialmente la geográfica– sin sacrificar de forma inaceptable su utilidad clínica.

1.2. Preguntas de investigación

- P1. Dado un modelo de riesgo con buen desempeño global sobre datos mexicanos, ¿existen disparidades de desempeño entre entidades federativas, grupos etarios y sexos?
- P2. ¿Cómo se relaciona la magnitud del sesgo geográfico con indicadores de infraestructura o marginación de cada entidad?
- P3. ¿Qué técnicas de mitigación –pre, in y post-procesamiento– reducen mejor esas disparidades, y cuál es el costo en desempeño global expresado como frontera de Pareto?
- P4. ¿Se transfieren tanto el desempeño como la equidad del modelo a una fuente de datos independiente?
- P5. De forma exploratoria, ¿aparecen inequidades adicionales en subgrupos interseccionales, por ejemplo adultos mayores de entidades marginadas?

1.3. Objetivos

1.3.1. Objetivo general

Desarrollar, auditar y mitigar la equidad –con énfasis en el sesgo geográfico entre entidades federativas– de un modelo de estratificación de riesgo clínico basado en datos abiertos de salud de México, valorando la transportabilidad de sus hallazgos.

1.3.2. Objetivos específicos

- OE1. Construir un canal reproducible de ingesta, limpieza y preparación de la base de la DGE, con control estricto de fuga de información.
- OE2. Entrenar un modelo de riesgo de referencia con desempeño comparable al estado del arte, como sujeto del análisis de equidad.
- OE3. Auditar la equidad del modelo por entidad federativa, sexo y grupo etario, y examinar la asociación del sesgo geográfico con indicadores contextuales.
- OE4. Aplicar y comparar técnicas de mitigación en las tres etapas del canal, construyendo la frontera de Pareto entre equidad y desempeño.
- OE5. Explorar la equidad en subgrupos interseccionales y traducir los hallazgos a recomendaciones de despliegue.

1.4. Hipótesis

- H1. Un modelo con buen desempeño global presentará disparidades de desempeño entre entidades federativas, medibles por *equalized odds* y calibración por grupo.
- H2. La magnitud del sesgo geográfico se asociará negativamente con la infraestructura de salud de cada entidad: peor desempeño donde hay menos recursos.
- H3. Las técnicas de mitigación reducirán las disparidades con una pérdida de desempeño global inferior a un umbral predefinido, cuantificable mediante la frontera de Pareto.
- H4. El desempeño se transferirá razonablemente a una fuente independiente, pero las disparidades podrían acentuarse, evidenciando la necesidad de recalibrado por contexto.

1.5. Contribuciones

- 1. La primera auditoría de equidad geográfica –entidad federativa como atributo sensible– de un modelo de riesgo clínico entrenado sobre datos abiertos mexicanos.
- 2. Evidencia de que la disparidad geográfica no se explica por composición etaria: persiste al restringir el análisis al subgrupo de 60 años o más.
- 3. Una comparación de las tres familias de mitigación bajo un punto de operación clínico común, que documenta una asimetría relevante: con 32 grupos de tamaño muy desigual, solo el post-procesamiento por umbrales de grupo reduce la disparidad de manera apreciable.
- 4. Una frontera de Pareto equidad–desempeño construida con umbrales estimados *fuera de muestra*, y la cuantificación de cuánto optimismo introduce estimarlos en el propio conjunto de prueba.
- 5. Evidencia de que la inequidad no es un problema de cobertura: un modelo que nunca vio una entidad se desempeña en ella casi igual que uno que sí la vio, y las brechas no se acentúan.
- 6. Un canal reproducible con contrato de datos explícito entre etapas (apéndice A).

1.6. Alcance y delimitaciones

Este documento reporta el trabajo correspondiente a las fases de datos, modelo de referencia, auditoría de equidad y mitigación. Para que la lectura de los resultados sea correcta, conviene fijar con precisión sus límites:

- **Cohorte.** Casos COVID confirmados ($\text{CLASIFICACION_FINAL} \in \{1, 2, 3\}$) del corte anual 2021 de la base de la DGE, $n = 2\,526\,649$. No se emplea la serie histórica completa.
- **Desenlace.** Mortalidad. La hospitalización se deriva y se describe en el análisis exploratorio, pero no se modela en este documento. En esta cohorte fallecer implica estar registrado como hospitalizado, de modo que el desenlace solo es posible en el 11.8 % de los casos; la sección 4.4 analiza las consecuencias.
- **Validación externa.** La transportabilidad a la base de Egresos Hospitalarios de la DGIS, que sustenta H4, *no* se ha ejecutado, y H4 se reporta como trabajo pendiente (sección 6.2). Sí se evalúa la generalización geográfica dentro de la misma fuente (sección 4.5), que no la sustituye.
- **Indicadores contextuales.** El examen de H2 se apoya en el índice de marginación por entidad de CONAPO 2020 (Consejo Nacional de Población, 2021), que es un agregado socioeconómico estatal. No se emplearon indicadores de infraestructura de salud por unidad médica, que serían el *proxy* más directo del mecanismo que H2 postula.
- **Interpretabilidad.** Se emplea importancia por permutación. No se calcularon valores SHAP ni análisis de curva de decisión.
- **Incertidumbre.** Las brechas del eje geográfico se acompañan de intervalos de confianza por remuestreo y de una prueba de permutación (sección 3.9). Los subgrupos interseccionales, en cambio, se reportan como estimaciones puntuales.

Nota metodológica. Los límites anteriores no son concesiones retóricas. Cualquier afirmación de esta tesis que dependa de H4 o de intervalos de confianza está marcada como preliminar en el punto donde aparece.

Capítulo 2

Marco teórico y trabajos relacionados

2.1. Modelos de riesgo clínico y su evaluación

Un modelo de estratificación de riesgo estima la probabilidad de un desenlace –aquí, la defunción– a partir de información disponible en el momento en que se toma la decisión clínica. Su evaluación exige separar dos propiedades que se confunden con frecuencia.

La **discriminación** mide la capacidad de ordenar pacientes por riesgo y se resume en el AUROC. Es insensible a transformaciones monótonas del puntaje: un modelo puede discriminar perfectamente y, aun así, emitir probabilidades absurdas. La **calibración** mide justamente eso: si de cada cien pacientes a quienes el modelo asigna un riesgo de 20 % fallecen efectivamente veinte. Se ha argumentado con razón que la calibración es el talón de Aquiles de la analítica predictiva en medicina, porque un modelo descalibrado desplaza sistemáticamente las decisiones de umbral sin que el AUROC lo delate (Van Calster et al., 2019). Esta distinción es central en el capítulo 4: el modelo de referencia de esta tesis discrimina bien desde el principio, pero requiere recalibrado explícito antes de poder auditarse.

En cohortes con desenlaces poco frecuentes, el AUPRC complementa al AUROC porque es sensible al desbalance de clases. Y como toda métrica agregada oculta la distribución de errores, la evaluación de un modelo destinado al despliegue debe reportarse en el *punto de operación* previsto y no en un umbral arbitrario. Las guías de reporte de modelos predictivos en salud recogen estos requisitos de manera sistemática (Collins et al., 2015), y la revisión crítica de modelos pronósticos de COVID-19 documentó que su incumplimiento fue masivo durante la pandemia: la mayoría de los modelos revisados presentaban alto riesgo de sesgo, principalmente por selección de cohorte, fuga de información y ausencia de validación (Wynants et al., 2020).

2.2. Aprendizaje automático sobre datos tabulares

Para datos tabulares heterogéneos, los ensambles de árboles con impulso del gradiente siguen siendo el punto de referencia práctico frente a arquitecturas neuronales. Las implementaciones basadas en histogramas agrupan los valores de cada variable en cubetas antes de buscar los cortes, lo que reduce el costo de entrenamiento de forma sustancial y las hace viables en millones de registros (Ke et al., 2017). En esta tesis se emplea `HistGradientBoostingClassifier` de *scikit-learn* (Pedregosa et al., 2011), que además maneja valores faltantes de forma nativa. Es una propiedad relevante aquí, porque la codificación de ausencia de la base de la DGE resulta informativa –el capítulo 4 lo cuantifica– y no conviene imputarla a ciegas.

El desbalance de clases se atiende reponderando la función de pérdida. Esa decisión tiene una consecuencia poco discutida: los puntajes resultantes dejan de ser probabilidades calibradas y sobreestiman el riesgo absoluto. La corrección estándar es una transformación monótona ajustada sobre datos no vistos, como la regresión isotónica (Zadrozny & Elkan, 2002). Por ser monótona, preserva el ordenamiento –y con él el AUROC– mientras corrige el nivel.

2.3. Equidad algorítmica

2.3.1. Definiciones

Sea A un atributo sensible, Y el desenlace observado, $\hat{Y}$ la predicción binaria y R el puntaje de riesgo. Las tres familias de criterios que se emplean en esta tesis son:

Paridad demográfica (independencia)

$P(\hat{Y} = 1 \mid A = a)$ constante en a . Iguala la tasa de selección entre grupos, sin condicionar al desenlace.

Equalized odds (separación)

$P(\hat{Y} = 1 \mid Y = y, A = a)$ constante en a para $y \in \{0, 1\}$; es decir, igualdad simultánea de sensibilidad (TPR) y tasa de falsos positivos (FPR) (Hardt et al., 2016). Su relajación a $y = 1$ –igualdad de oportunidades– es la que más importa clínicamente: significa que el modelo detecta a quien va a fallecer con la misma probabilidad en todos los grupos.

Calibración por grupo (suficiencia)

$P(Y = 1 \mid R = r, A = a)$ constante en a . Significa que un riesgo de 0.3 quiere decir

lo mismo en cada entidad federativa.

2.3.2. El teorema de imposibilidad

Estos criterios no pueden satisfacerse a la vez. Cuando la prevalencia del desenlace difiere entre grupos y el clasificador no es perfecto, calibración por grupo y *equalized odds* son mutuamente incompatibles (Chouldechova, 2017; Kleinberg et al., 2017).

El resultado no es un tecnicismo, y conviene enunciar con precisión la forma que toma aquí. Las tasas de mortalidad por entidad difieren por un factor de 5.6, de modo que sobre un puntaje bien calibrado ningún conjunto de reglas de decisión puede igualar *a la vez* la sensibilidad y la tasa de falsos positivos entre entidades. Sí puede igualarse *una* de las dos: un umbral por grupo deja intacta la calibración –que es propiedad del puntaje y no de la regla– y permite escoger cuál de las dos tasas se reparte por igual, a costa de desigualar la otra. Es lo que ocurre en el capítulo 4. La elección entre criterios es, por tanto, normativa y no estadística, y por eso el entregable adecuado no es un único modelo «justo» sino una frontera que explicita el intercambio.

2.3.3. Mitigación

Las técnicas se clasifican por la etapa del canal en la que intervienen:

Pre-procesamiento

Modifican los datos antes de entrenar: reponderación de muestras, remuestreo o corrección de representación. Son agnósticas al modelo, pero solo actúan sobre el desequilibrio de representación.

In-procesamiento

Incorporan la restricción de equidad en la optimización. La reducción por gradiente exponenciado convierte el problema restringido en una secuencia de problemas ponderados y admite restricciones de *equalized odds* (Bird et al., 2020).

Post-procesamiento

Ajustan la regla de decisión sobre un modelo ya entrenado, típicamente eligiendo un umbral por grupo (Hardt et al., 2016). Son las más eficaces cuando el problema no es el ordenamiento sino dónde se corta, y las más controvertidas porque usan el atributo sensible en el momento de la decisión.

Un problema abierto especialmente pertinente aquí es la equidad de subgrupos pequeños: al desagregar por 32 entidades, los estados con menos registros producen estimaciones de

TPR con varianza alta, y los métodos que optimizan brechas máximas tienden a perseguir ruido.

2.4. Trabajos relacionados y vacío de investigación

2.4.1. La parte predictiva mexicana está saturada

Varios trabajos revisados por pares construyen modelos de riesgo sobre la base abierta mexicana con buen desempeño. Becerra-Sánchez et al. (2022) comparan modelos sobre datos mexicanos y alcanzan alrededor de 90 % de exactitud, identificando neumonía, edad avanzada e intubación como principales factores asociados a la mortalidad. Méndez-Astudillo (2024) aplica *random forest* y XGBoost sobre más de veinte millones de observaciones y concluye que diabetes e hipertensión, junto con la desigualdad económica, definen la mortalidad.

La implicación metodológica es directa: replicar el esquema «clasificador más atribución de importancia sobre comorbilidades» sería un trabajo derivativo. Por eso el modelo predictivo se adopta aquí como línea de base y no como aportación.

Nota metodológica. La variable INTUBADO que aparece entre los factores más informativos en parte de esta literatura describe el curso hospitalario y no está disponible al primer contacto. Usarla como predictor de mortalidad en ese punto constituye fuga de información. Esta tesis la excluye explícitamente (sección 3.2).

2.4.2. Lo geográfico ya se estudió, pero como predictor

Un trabajo mexicano reciente muestra que los factores de ubicación –municipio, unidad médica, entidad de nacimiento y de residencia– superan incluso a la edad como predictores de mortalidad por COVID-19 en México (Maldonado-Sifuentes et al., 2024). Es un hallazgo relevante que debe reconocerse, pero responde a una pregunta distinta.

La diferencia es sustantiva. Ese estudio usa la geografía como variable de *entrada* para responder «¿dónde vives predice tu desenlace?», una pregunta de epidemiología espacial. Esta tesis usa la geografía como eje de *auditoría* para responder «¿el modelo comete más errores en unas entidades que en otras, y cómo se corrige?», una pregunta de equidad algorítmica. Que la entidad sea informativa como predictor no dice nada sobre si el modelo es igualmente confiable en cada entidad; son propiedades independientes.

2.4.3. La equidad algorítmica en salud es madura, pero fuera de México

La literatura de equidad en salud es rica y está anclada en otros contextos y otros atributos sensibles. Nejadshamsi et al. (2026) auditan y mitigan el sesgo por sexo en clasificación de severidad de COVID-19 con datos de Canadá. En imagen médica se ha documentado sistemáticamente cómo los sesgos de composición de las cohortes de entrenamiento se trasladan al desempeño por subgrupo (Ricci Lara et al., 2022). No se identificó trabajo alguno que use datos mexicanos tratando la entidad federativa como atributo sensible ligado a la desigualdad de infraestructura de salud.

2.4.4. El vacío que ocupa esta tesis

Tabla 2.1: Posición de esta tesis respecto de la literatura.

Dimensión	Estado en la literatura	Aporte de esta tesis
Predicción de desenlace (MX)	Saturado	Línea de base, no aportación
Geografía como predictor (MX)	Estudiado	Se distingue: geografía como eje de equidad
Equidad en salud	Madura, fuera de México	Se traslada y adapta al contexto mexicano
Auditoría de equidad por entidad (MX)	No identificado	Eje central y original
Mitigación y frontera de Pareto (MX)	No identificado	Instrumento de decisión entregable
Validación externa de la equidad	Rara vez realizada	Pendiente (véase sección 1.6)

En una frase: sabemos que la geografía predice la mortalidad en México y que la equidad algorítmica importa en otros países, pero nadie ha preguntado todavía si un modelo clínico entrenado con datos mexicanos es igual de preciso entre entidades federativas, ni cómo corregir esa inequidad.

Capítulo 3

Metodología

3.1. Fuente de datos y cohorte

La fuente primaria es la base abierta de COVID-19 de la Dirección General de Epidemiología (DGE) de la Secretaría de Salud. Se emplea el corte anual `COVID19MEXICO2021.csv`, que contiene 8 830 345 registros de notificación del año 2021 con variables demográficas, entidad de residencia, comorbilidades y desenlaces.

Como fuente de contexto se emplea el índice de marginación por entidad federativa de CONAPO, edición 2020, construido sobre el Censo de Población y Vivienda 2020 del INEGI (Consejo Nacional de Población, 2021). Se usa el archivo por entidad (`IME_2020.xls`), del que se toman el índice y el grado de marginación.

La cohorte de análisis se restringe a **casos COVID confirmados** (`CLASIFICACION_FINAL` $\in \{1, 2, 3\}$), lo que produce $n = 2\,526\,649$ registros con una mortalidad observada de 5.60 %. La restricción es deliberada: un modelo de mortalidad *por COVID* debe estimarse sobre enfermos de COVID. Incluir casos negativos y sospechosos mezcla poblaciones con mecanismos de riesgo distintos y diluye la señal; la prevalencia del desenlace cae entonces a 2.06 % y el modelo pasa a describir mortalidad en población tamizada, que es otra pregunta.

3.2. Definición de desenlaces y control de fuga de información

El desenlace modelado es la **defunción**, derivada del campo `FECHA_DEF`: la base codifica 9999-99-99 para paciente vivo.

Nota metodológica. La cohorte tiene una propiedad estructural que condiciona la lectura de todo el capítulo de resultados y conviene declarar aquí. Entre los casos confirmados, el número de defunciones registradas como ambulatorias es 0: fallecer implica estar registrado como hospitalizado. El desenlace solo es posible, por tanto, en el 11.8 % de la cohorte ($n = 297\,685$), y el resto son casos que no pueden fallecer por construcción. Esto no invalida la tarea –estimar riesgo al primer contacto sobre todo caso confirmado es precisamente el triage que motiva la tesis– pero significa que parte de la discriminación consiste en separar ambulatorios de hospitalizados. La sección 3.8 cuantifica cuánta.

El control de fuga de información es la decisión metodológica más importante del canal. El punto de predicción es el *primer contacto*, de modo que ninguna variable posterior a ese momento puede ser predictor. Se excluyen explícitamente:

- UCI e INTUBADO, que describen el curso hospitalario y solo se conocen después de la decisión que el modelo pretende apoyar.
- FECHA_DEF y todo lo derivado de ella, salvo el desenlace mismo.
- TIPO_PACIENTE como predictor de mortalidad, por ser posterior al triage.

Los predictores admitidos son la edad, el sexo y once comorbilidades o signos registrados al primer contacto: diabetes, EPOC, asma, inmunosupresión, hipertensión, otra comorbilidad, enfermedad cardiovascular, obesidad, enfermedad renal crónica, tabaquismo y neumonía.

Nota metodológica. La inclusión de NEUMONIA merece justificación. En el formato de la DGE se captura en el primer contacto y no durante la evolución hospitalaria, por lo que es admisible en ese punto. Aun así resulta el predictor más informativo del modelo (sección 4.2.2), de modo que la validez de esa captura es un supuesto del que dependen los resultados. La sección 4.4 reentrena el modelo sin ella para acotar cuánto del desempeño y de la inequidad descansan en esa única variable.

3.3. Limpieza y recodificación

La base codifica las categóricas con enteros y usa códigos especiales para ausencia: 97 (no aplica), 98 (se ignora) y 99 (no especificado). El tratamiento aplicado es:

- **Edad.** Valores fuera de $[0, 120]$ se marcan como faltantes.

- **Sexo.** Se deriva un indicador binario `sexo_mujer` (1 = mujer), dejando faltante el código 99.
- **Entidad.** `ENTIDAD_RES` se traduce a nombre mediante el catálogo de 32 entidades; los códigos 97–99 quedan sin etiqueta.
- **Comorbilidades.** Cada variable produce dos columnas: una binaria (1 = sí, 0 = no, faltante en otro caso) y un *indicador de faltante*. La codificación de ausencia se conserva como información en lugar de imputarse a ciegas, porque su frecuencia difiere entre entidades y es en sí un posible mecanismo de inequidad.
- **Grupo etario.** Cortes en 0–17, 18–39, 40–59 y 60 o más años, definidos una única vez para todo el canal.

3.4. Partición de datos

Se emplea una partición en tres bloques, estratificada por el desenlace con semilla fija:

1. **Prueba** (25 %, $n = 631\,663$). Se separa primero y no interviene en ninguna decisión de ajuste.
2. **Calibración** (20 % del resto, $n = 378\,998$). Se usa exclusivamente para ajustar la transformación de calibración y los umbrales por grupo de la mitigación post-procesamiento.
3. **Entrenamiento** (el remanente, $n = 1\,515\,988$). Ajuste de los modelos.

El tercer bloque es necesario, y no un refinamiento cosmético. Tanto la calibración como los umbrales por entidad son parámetros ajustados a datos; si se estiman sobre el conjunto de prueba, las métricas resultantes están sesgadas optimistamente. La sección 4.6 cuantifica esa diferencia.

3.5. Modelo de referencia

Se entrenan dos modelos sobre los mismos predictores:

Regresión logística

Con imputación por mediana, estandarización y `class_weight="balanced"`. Sirve como referencia interpretable.

Impulso del gradiente por histogramas

`HistGradientBoostingClassifier` con 300 iteraciones, tasa de aprendizaje 0.05, profundidad máxima 6 y `class_weight="balanced"`. Es el modelo principal y el sujeto de la auditoría.

Ninguno de los dos incorpora la entidad federativa como predictor: la entidad se reserva como atributo sensible para auditar, no como variable de entrada.

3.5.1. Calibración

El desbalance de clases del desenlace es de 16.9 a 1, y el parámetro `class_weight` en modo `balanced` lo compensa reponderando la pérdida en proporción inversa a la frecuencia de cada clase. Como consecuencia, el modelo sobreestima el riesgo absoluto por un factor cercano a cuatro (sección 4). Se aplica por tanto una **regresión isotónica** ajustada sobre el bloque de calibración. Al ser una transformación monótona, preserva el ordenamiento –y por tanto el AUROC– y corrige el nivel de la probabilidad.

Esta corrección es un requisito previo a la auditoría, no un adorno: sin ella, el error de calibración medido por grupo queda dominado por el sesgo global de entrenamiento y no por la inequidad entre grupos, que es el objeto de estudio.

3.5.2. Punto de operación

Todas las métricas dependientes de umbral se reportan en un punto de operación único: el umbral τ que alcanza una **sensibilidad global de 80 %**, propia de una herramienta de triage cuyo costo de omitir una defunción excede con holgura el de una alarma innecesaria. Para el modelo calibrado resulta $\tau = 0.1562$. Fijar el mismo punto de operación en todas las etapas es lo que hace comparables las tablas de desempeño, auditoría y mitigación entre sí.

3.6. Métricas

Las métricas de equidad se implementan explícitamente en lugar de delegarse a una biblioteca, para que el cálculo sea auditable línea por línea; son equivalentes a las definiciones de Fairlearn (Bird et al., 2020).

Tabla 3.1: Métricas empleadas por dimensión de evaluación.

Dimensión	Métricas
Discriminación	AUROC; AUPRC; sensibilidad y tasa de falsos positivos en el punto de operación
Calibración	Puntaje de Brier; curva de calibración por deciles; riesgo medio predicho frente a observado, global y por grupo
Equidad	Brecha máxima de TPR (<i>equalized odds</i>); brecha de FPR; brecha de AUROC; brecha de tasa de selección (paridad demográfica); error máximo de calibración por grupo
Interpretabilidad	Importancia por permutación sobre el AUROC
Utilidad agregada	Exactitud balanceada en el punto de operación

3.6.1. Criterio de soporte por grupo

Un grupo se considera evaluable si tiene al menos 500 observaciones y 20 casos positivos en el bloque correspondiente. Por debajo de ese soporte, la estimación de sensibilidad tiene una varianza que domina cualquier señal de inequidad. Los grupos descartados se reportan explícitamente en lugar de omitirse en silencio; con la cohorte empleada, las 32 entidades superan el criterio.

En el análisis interseccional el mínimo se relaja a 300 observaciones. Exigir 500 dentro de un subgrupo etario dejaría fuera precisamente a las entidades pequeñas, que son las que interesa examinar. La sección 4.3.4 reporta el resultado bajo ambos criterios para que la conclusión no dependa de esa elección.

3.7. Estrategias de mitigación

Se evalúan las tres familias bajo el mismo punto de operación:

Pre-procesamiento

Reponderación de muestras inversamente proporcional al número de registros de cada entidad, de modo que los estados con menos datos pesen más durante el entrenamiento. Se reentrena el modelo con los hiperparámetros idénticos a los de la línea de base, para que la única diferencia sean los pesos.

In-procesamiento

Reducción por gradiente exponenciado con restricción de *equalized odds* (Bird et al., 2020), sobre una submuestra de 120 000 registros del bloque de entrenamiento y con un clasificador lineal como aprendiz base, dado que el método reentrena el modelo

en cada iteración. Esta limitación la hace no comparable uno a uno con las demás intervenciones, y así se reporta.

Post-procesamiento

Un umbral por entidad, elegido para alcanzar la sensibilidad objetivo *dentro* de cada estado. Los umbrales se estiman en el bloque de calibración y se evalúan en el de prueba.

3.7.1. Frontera de Pareto

La frontera se traza interpolando linealmente entre el umbral global y el umbral por entidad,

$$\tau_g(\alpha) = (1 - \alpha) \tau + \alpha \tau_g, \quad \alpha \in [0, 1], \quad (3.1)$$

donde τ_g es el umbral estimado para la entidad g . Cada valor de α define una política de despliegue: $\alpha = 0$ es el modelo sin mitigar y $\alpha = 1$ la corrección completa por entidad. El conjunto de pares (brecha de sensibilidad, desempeño global) constituye el instrumento de decisión entregable, porque traslada al responsable de la política una elección que es normativa y no técnica.

3.8. Análisis de sensibilidad: subconjunto hospitalizado

Se reentrena el modelo, con los mismos hiperparámetros y el mismo esquema de partición, restringido a los pacientes hospitalizados. Es la población en la que el desenlace es posible, la que corresponde a los modelos clínicos de mortalidad hospitalaria con los que suele compararse un trabajo de este tipo, y la que tendría una eventual validación externa sobre bases de egresos.

Se reentrena en lugar de restringir a posteriori el conjunto de prueba del modelo global, porque ese modelo habría aprendido de ambulatorios y la comparación mediría otra cosa. El AUPRC se reporta junto con su razón respecto de la prevalencia, que es su línea base: sin normalizar, dos AUPRC de cohortes con prevalencias de 5.6 % y 47.5 % no son comparables.

3.9. Cuantificación de la incertidumbre

Las brechas se calculan como diferencia entre el máximo y el mínimo de 32 grupos de tamaños muy desiguales. Ese estadístico está sesgado al alza: aun sin ningún efecto de entidad, el máximo y el mínimo de 32 estimaciones ruidosas se separan por azar. Reportarlo como estimación puntual, sin referencia, invita a sobreinterpretarlo. Se emplean por ello dos procedimientos complementarios.

El primero es un **remuestreo estratificado por entidad**: 1000 réplicas en las que cada entidad se remuestra con reemplazo conservando su tamaño, de las que se obtienen intervalos de confianza al 95 % por percentiles para el AUROC y la sensibilidad de cada estado. Se estratifica dentro de la entidad, y no sobre todo el conjunto, para que el intervalo refleje la precisión con que se estima *ese* estado; las entidades pequeñas deben salir con intervalos anchos.

El segundo es una **prueba de permutación**: 1000 reasignaciones al azar de la etiqueta de entidad, conservando los tamaños de grupo, que construyen la distribución de la brecha bajo la hipótesis nula de que la entidad no influye en el desempeño. El valor p se calcula con la corrección de continuidad habitual, $(\#\{\text{nula} \geq \text{observada}\} + 1)/(P + 1)$, de modo que nunca resulta exactamente cero. Es este contraste, y no el intervalo de confianza, el que permite afirmar si las disparidades son *estadísticamente significativas*, que es la formulación de la hipótesis H1.

3.10. Transportabilidad geográfica interna

La partición aleatoria reparte cada entidad entre entrenamiento y prueba, de modo que el modelo siempre ha visto casos del estado en el que se le evalúa. Eso mide interpolación dentro de una población conocida, no generalización a un contexto nuevo, que es lo que importa para desplegar en una entidad cuyo perfil no estaba en los datos de ajuste.

Se entrenan por ello 32 modelos: cada uno excluye por completo una entidad y se evalúa sobre la totalidad de sus registros. La calibración se ajusta sobre un bloque tallado de las entidades restantes, y el umbral se fija para alcanzar la sensibilidad objetivo *en esas entidades* –nunca en la excluida–, porque en despliegue no se conoce el desenlace del estado nuevo. La pérdida por transportabilidad es la diferencia entre el AUROC de una entidad cuando participó en el entrenamiento y cuando no.

Nota metodológica. Este diseño *no* pone a prueba la hipótesis H4, que habla de una fuente independiente: aquí la fuente, el año y el proceso de captura son los mismos. Lo que

somete a prueba es la generalización geográfica, que es el eje del trabajo. H4 sigue pendiente (sección 6.2).

3.11. Reproducibilidad

El canal se implementa en cuatro cuadernos ejecutados en orden, con semillas fijas y un contrato de datos explícito entre etapas que verifica procedencia, esquema y cohorte antes de consumir cualquier artefacto. Las cifras del capítulo 4 no se transcriben a mano: se generan a partir de los archivos de resultados que exportan los cuadernos. El apéndice A documenta el mecanismo.

Capítulo 4

Resultados

4.1. Caracterización de la cohorte

La cohorte de análisis comprende $n = 2\,526\,649$ casos COVID confirmados del año 2021 –de 8 830 345 registros de notificación en el corte anual– con una mortalidad observada de 5.60 % y una tasa de hospitalización de 11.78 %. A modo de contraste, la mortalidad sobre la base completa, que incluye casos negativos y sospechosos, es de 2.06 %: la restricción a casos confirmados no es un detalle de filtrado, sino la diferencia entre dos poblaciones con riesgo basal muy distinto.

La calidad del dato es alta en las variables clave: la edad tiene 0.0013 % de valores faltantes y el sexo y la entidad de residencia están completos. En las comorbilidades, la proporción de códigos de ausencia (97–99) oscila entre 0.17 % y 0.88 %, con el máximo en `OTRA_COM`.

Esa ausencia no es ruido aleatorio, lo que justifica conservarla en lugar de imputarla. En nueve de las once comorbilidades, los registros con código de ausencia tienen una mortalidad hasta 2.2 veces mayor que los que sí están codificados: en `EPOC`, 12.5 % frente a 5.6 %. En `NEUMONIA` la relación se invierte por completo (razón 0.017), lo que es coherente con que sea el predictor dominante: no registrar neumonía acompaña a los casos leves. Además su frecuencia difiere enormemente entre estados: la máxima proporción de faltantes por entidad va de 0.02 % en Quintana Roo a 5.55 % en México. Es, por tanto, un mecanismo plausible de inequidad geográfica que este trabajo documenta pero no explota: los indicadores de ausencia no se usan como predictores (apéndice B).

La figura 4.1 muestra la heterogeneidad que motiva la tesis. El tamaño de muestra por entidad varía por un factor de 43 –de 15 221 a 651 956 registros– y las tasas de defunción difieren por un factor de 5.6 entre los extremos. Esa doble heterogeneidad –de volumen y de riesgo basal– es la condición de la que cabe esperar desempeño desigual.




Figura 4.1: Heterogeneidad entre entidades federativas en la cohorte: tasa de defunción (izquierda) y tamaño de muestra (derecha).

4.2. Desempeño del modelo de referencia

El modelo principal alcanza un **AUROC de 0.9503** y un AUPRC de 0.5533 sobre el conjunto de prueba ($n = 631\,663$), entrenado sobre 1 515 988 registros y calibrado sobre 378 998. La regresión logística obtiene un AUROC de 0.9489, apenas por debajo, lo que indica que la señal disponible en edad, sexo y comorbilidades es en buena medida lineal y que el impulso del gradiente aporta poco en discriminación.

La comparación con la literatura sobre esta misma base debe hacerse con cautela, porque los trabajos de referencia reportan exactitud y F_1 y no AUROC (Becerra-Sánchez et al., 2022; Méndez-Astudillo, 2024), de modo que las cifras no son directamente homologables. Lo que sí puede afirmarse es que el modelo no está deliberadamente debilitado: usa los predictores habituales de esa literatura, un algoritmo del mismo tipo y una cohorte de la misma fuente, y coincide con ella en qué variables resultan más informativas (sección 4.2.2). Eso basta para el propósito de la línea de base, que es que el sujeto de la auditoría sea un modelo razonable y no un espantapájaros.

4.2.1. Efecto de la calibración

El modelo sin calibrar discrimina bien pero está severamente descalibrado: emite un riesgo medio de 0.205 frente a una mortalidad observada de 0.056, es decir una sobreestima-

ción por un factor de 3.7, consecuencia directa de la reponderación por clase. La regresión isotónica ajustada sobre el bloque de calibración reduce el puntaje de Brier de 0.0866 a 0.0323 y alinea el riesgo medio predicho (0.056) con el observado, dejando el AUROC esencialmente intacto -0.9503 frente a 0.9504 — como corresponde a una transformación monótona.

Nota metodológica. Este resultado tiene una consecuencia que va más allá del ajuste. Una auditoría de calibración por grupo realizada sobre el puntaje sin calibrar habría reportado un error máximo de calibración por entidad de 0.2108, cifra que corresponde casi enteramente al sesgo global de entrenamiento y no a la inequidad geográfica. Medida sobre el riesgo calibrado, la misma métrica es 0.0231. La conclusión sustantiva se invierte: la calibración por entidad, una vez corregido el nivel global, es *buen*a.

4.2.2. Importancia de variables

La importancia por permutación sobre el AUROC (tabla 4.1) concentra la señal en dos variables: NEUMONIA (0.106) y la edad (0.079). El resto de los predictores aporta 0.003 o menos cada uno. La concentración es coherente con la literatura sobre esta base (Becerra-Sánchez et al., 2022), y refuerza la advertencia de la sección 3.2: la validez del modelo depende de que la neumonía esté efectivamente registrada al primer contacto.

Tabla 4.1: Importancia por permutación sobre el AUROC en el conjunto de prueba (3 repeticiones, submuestra de 50 000 observaciones).

Variable	Caída de AUROC
NEUMONIA	0.1057
EDAD	0.0789
sexo_mujer	0.0029
DIABETES	0.0028
RENAL_CRONICA	0.0016
OBESIDAD	0.0011
OTRA_COM	0.0010
HIPERTENSION	0.0009
INMUSUPR	0.0002
TABAQUISMO	0.0001
CARDIOVASCULAR	0.0001
EPOC	0.0000
ASMA	0.0000

4.3. Auditoría de equidad

Todas las métricas dependientes de umbral se evalúan en el punto de operación común $\tau = 0.1562$, que alcanza una sensibilidad global de 0.795 con una tasa de falsos positivos de 0.059.

4.3.1. Entidad federativa

La tabla 4.3 presenta el desempeño por entidad, la tabla 4.2 resume las brechas por eje de auditoría y la figura 4.2 las visualiza. El hallazgo central es una **disparidad geográfica sustantiva**: la sensibilidad varía 0.2935 entre entidades y el AUROC 0.0563. El peor desempeño corresponde a Chihuahua (AUROC 0.9207, sensibilidad 0.688) y el mejor a Tabasco (AUROC 0.9770, sensibilidad 0.879).

La magnitud merece leerse en términos clínicos y no estadísticos. Con un umbral único calibrado para detectar al 80 % de las defunciones a nivel nacional, el modelo detecta cerca de 69 de cada 100 en la entidad peor servida y 88 de cada 100 en la mejor servida. La diferencia –unas 19 defunciones no priorizadas por cada 100– recae sobre la población de un estado concreto por el solo hecho de residir en él.

Tabla 4.2: Brechas máximas entre grupos por eje de auditoría, al umbral $\tau = 0.1562$. La brecha de TPR corresponde a la violación de *equalized odds*; el error de calibración se mide sobre el riesgo calibrado.

Eje	Δ TPR	Δ FPR	Δ AUROC	Δ Selec.	Err. calib.
Entidad federativa	0.2935	0.0867	0.0563	0.1556	0.0231
Sexo	0.0393	0.0268	0.0082	0.0448	0.0005
Grupo etario	0.5824	0.3026	0.0903	0.4408	0.0008

Tabla 4.3: Desempeño y equidad por entidad federativa en el conjunto de prueba ($n = 631\,663$), al umbral de sensibilidad objetivo $\tau = 0.1562$. Ordenadas por AUROC ascendente.

Entidad	n	Mort.	AUROC	TPR	FPR	Riesgo
Chihuahua	11 072	0.0713	0.9207	0.688	0.081	0.0659
Chiapas	3 831	0.0611	0.9265	0.662	0.065	0.0567
Baja California Sur	11 712	0.0307	0.9272	0.683	0.040	0.0347
Aguascalientes	5 498	0.0615	0.9304	0.657	0.060	0.0532
Durango	6 297	0.0569	0.9310	0.631	0.052	0.0465
Veracruz	20 275	0.1012	0.9340	0.766	0.086	0.0826

Continúa en la página siguiente

Entidad	n	Mort.	AUROC	TPR	FPR	Riesgo
Nuevo León	32 110	0.0528	0.9341	0.686	0.046	0.0449
Coahuila	12 615	0.0576	0.9342	0.686	0.054	0.0502
Jalisco	27 918	0.0887	0.9348	0.703	0.067	0.0656
Michoacán	9 484	0.1281	0.9359	0.853	0.116	0.1114
México	65 705	0.0720	0.9387	0.760	0.070	0.0634
Tlaxcala	4 288	0.0702	0.9391	0.841	0.100	0.0780
Sinaloa	12 274	0.0849	0.9394	0.799	0.076	0.0735
Nayarit	6 700	0.0710	0.9402	0.700	0.049	0.0537
Hidalgo	9 345	0.1022	0.9410	0.881	0.123	0.1011
Zacatecas	5 534	0.0614	0.9431	0.773	0.067	0.0591
Yucatán	12 490	0.0705	0.9440	0.726	0.048	0.0515
Puebla	18 800	0.1130	0.9480	0.920	0.118	0.1083
Oaxaca	13 461	0.0558	0.9512	0.792	0.060	0.0560
Querétaro	16 305	0.0449	0.9530	0.816	0.055	0.0497
Tamaulipas	15 876	0.0544	0.9539	0.809	0.048	0.0509
Campeche	4 191	0.0625	0.9544	0.920	0.111	0.0837
Guanajuato	29 653	0.0575	0.9579	0.833	0.061	0.0586
Baja California	13 953	0.0754	0.9584	0.887	0.080	0.0782
Colima	6 390	0.0444	0.9598	0.824	0.052	0.0496
Morelos	9 756	0.0763	0.9600	0.914	0.095	0.0875
Ciudad de México	162 746	0.0262	0.9607	0.808	0.040	0.0367
Quintana Roo	12 151	0.0414	0.9623	0.813	0.041	0.0393
Sonora	16 698	0.0562	0.9628	0.868	0.064	0.0621
San Luis Potosí	17 326	0.0459	0.9647	0.868	0.057	0.0528
Guerrero	12 589	0.0666	0.9679	0.925	0.080	0.0751
Tabasco	24 620	0.0222	0.9770	0.879	0.036	0.0348

Conviene notar la disociación entre criterios de equidad. El error máximo de calibración por entidad es 0.0231, es decir, la probabilidad emitida significa aproximadamente lo mismo en cada estado; sin embargo la brecha de sensibilidad es 0.2935. Un modelo puede estar bien calibrado en todos los grupos y repartir la sensibilidad de forma muy desigual: es exactamente el comportamiento que anticipa el teorema de imposibilidad cuando las prevalencias difieren entre grupos (Chouldechova, 2017; Kleinberg et al., 2017). Conviene subrayar que la calibración es propiedad del puntaje y no de la regla de decisión, de modo que el error de 0.0231 no se altera por ninguna elección de umbral, incluida la mitigación de la sección 4.6. El mecanismo es directo: con un umbral fijo sobre un puntaje bien calibrado,




Figura 4.2: Auditoría por entidad federativa: sensibilidad frente al objetivo global (izquierda), AUROC (centro) y calibración, riesgo medio predicho frente a mortalidad observada (derecha).

la fracción de positivos que quedan por encima del corte depende de la distribución de riesgo dentro del grupo, y esa distribución es distinta en cada entidad.

4.3.2. Incertidumbre de las brechas

Las cifras anteriores son estimaciones puntuales sobre un único conjunto de prueba. La tabla 4.4 añade intervalos de confianza al 95 % por remuestreo y la tabla 4.5 contrasta las brechas contra su distribución bajo la hipótesis nula de que la entidad no influye (sección 3.9).

Tabla 4.4: Desempeño por entidad con intervalos de confianza al 95 % obtenidos por remuestreo estratificado (1000 réplicas); cinco peores y cinco mejores por AUROC.

Entidad	<i>n</i>	AUROC	IC 95 %	TPR	IC 95 %
Chihuahua	11 072	0.9207	[0.9125, 0.9290]	0.688	[0.654, 0.720]
Chiapas	3 831	0.9265	[0.9116, 0.9407]	0.662	[0.604, 0.721]
Baja California Sur	11 712	0.9272	[0.9135, 0.9398]	0.683	[0.635, 0.731]
Aguascalientes	5 498	0.9304	[0.9182, 0.9418]	0.657	[0.603, 0.705]
Durango	6 297	0.9310	[0.9190, 0.9427]	0.631	[0.580, 0.680]
Quintana Roo	12 151	0.9623	[0.9539, 0.9699]	0.813	[0.777, 0.845]
Sonora	16 698	0.9628	[0.9582, 0.9677]	0.868	[0.847, 0.889]
San Luis Potosí	17 326	0.9647	[0.9587, 0.9701]	0.868	[0.844, 0.891]
Guerrero	12 589	0.9679	[0.9635, 0.9720]	0.925	[0.907, 0.943]
Tabasco	24 620	0.9770	[0.9717, 0.9820]	0.879	[0.851, 0.907]

Tabla 4.5: Prueba de permutación sobre las brechas entre entidades (1000 permutaciones de las etiquetas de entidad, conservando los tamaños de grupo). La brecha bajo la nula no es cero: con 32 grupos, máximo y mínimo se separan por azar.

Brecha	Observada	IC 95 %	Nula (mediana)	<i>p</i>
AUROC	0.0563	[0.0496, 0.0697]	0.0175	0.001
Sensibilidad	0.2935	[0.2671, 0.3535]	0.0737	0.001




Figura 4.3: Izquierda: AUROC por entidad con intervalo de confianza al 95 %. Derecha: distribución de la brecha de AUROC bajo la hipótesis nula de ausencia de efecto de entidad, frente a la brecha observada.

El resultado más importante es que **las brechas bajo la nula no son cero**. Permutando al azar las etiquetas de entidad, la brecha mediana de AUROC es 0.0175 y la de sensibilidad 0.0737: con 32 grupos de tamaños desiguales, el máximo y el mínimo se separan por azar sin que haya efecto alguno. Ese es el punto de comparación correcto, y no el cero.

Contra esa referencia, las brechas observadas son claramente excesivas. La de AUROC, 0.0563 (IC 95 %: 0.0496–0.0697), supera el percentil 95 de la nula (0.0252); la de sensibilidad, 0.2935 (IC 95 %: 0.2671–0.3535), supera con holgura el suyo (0.1062). En ambos casos $p = 0.001$ y $p = 0.001$ respectivamente, que es el mínimo alcanzable con 1000 permutaciones: ninguna reasignación al azar produjo una brecha tan grande como la real.

Conviene traducir esto a la magnitud del efecto. De la brecha de sensibilidad observada, alrededor de 0.0737 es lo que el azar produce con esta estructura de grupos; el exceso atribuible a la entidad es de aproximadamente 0.2198. Sigue siendo grande, pero es la cifra honesta.

A nivel de entidad individual, 261 de los 496 pares posibles tienen intervalos de AUROC disjuntos (53 %), y los extremos –Chihuahua y Tabasco– lo están. La precisión es razonable incluso en las entidades pequeñas: el intervalo más ancho es el de Chiapas ($n = 3\,831$), con una amplitud de 0.029. El ordenamiento fino de la tabla 4.3 no debe leerse posición por posición, pero la separación entre los extremos no es ruido.

4.3.3. Sexo y grupo etario

Las tablas 4.6 y 4.7 presentan los otros dos ejes. El sesgo por **sexo** es pequeño: la brecha de sensibilidad es 0.0393 y la de AUROC 0.0082. El sesgo por **grupo etario** es el mayor de los tres –brecha de sensibilidad 0.5824 y de AUROC 0.0903– pero su interpretación es distinta.

Tabla 4.6: Desempeño y equidad por sexo en el conjunto de prueba.

Sexo	n	Mort.	AUROC	TPR	FPR	Selecc.	Riesgo
Hombre	309 437	0.0681	0.9456	0.811	0.073	0.123	0.0676
Mujer	322 226	0.0444	0.9538	0.772	0.046	0.079	0.0444

La brecha etaria es en buena medida mecánica y no debe leerse como inequidad en el mismo sentido. La edad es el segundo predictor más informativo y las tasas base difieren por dos órdenes de magnitud: 0.29 % en menores de 18 años frente a 25.6 % en el grupo de 60 o más. Con un umbral único sobre un puntaje calibrado, un grupo con riesgo basal muy bajo cae casi enteramente por debajo del corte, y su sensibilidad se hunde por construcción: en 0–17 años es 0.266 con una tasa de selección de 0.4 %. Igualar la sensibilidad entre grupos

Tabla 4.7: Desempeño y equidad por grupo etario en el conjunto de prueba.

Grupo etario	n	Mort.	AUROC	TPR	FPR	Selec.	Riesgo
0-17	47 676	0.0029	0.9347	0.266	0.003	0.004	0.0027
18-39	303 100	0.0089	0.9346	0.608	0.015	0.020	0.0089
40-59	196 593	0.0558	0.9039	0.743	0.062	0.100	0.0554
60+	84 285	0.2560	0.8444	0.849	0.306	0.445	0.2552

etarios exigiría seleccionar una fracción mucho mayor de menores, con un valor predictivo positivo muy bajo, algo difícil de justificar clínicamente. La disparidad geográfica no admite esa explicación, porque las entidades no difieren en riesgo basal de forma comparable ni la entidad es un predictor del modelo.

4.3.4. Análisis interseccional

Para descartar que la brecha geográfica sea un reflejo de la composición etaria de cada estado, se repite la auditoría restringiendo la muestra a adultos de **60 años o más** (tabla 4.8). La disparidad no desaparece: el AUROC varía de 0.688 en Chiapas a 0.942 en Tabasco, un rango de 0.254 frente a 0.0563 en la población completa.

Tabla 4.8: Subgrupo interseccional: adultos de 60 años o más, por entidad (cinco peores y cinco mejores de 32 evaluadas). El deterioro persiste tras controlar por edad avanzada.

Entidad	n	Mortalidad	AUROC	TPR
Chiapas	482	0.322	0.688	0.748
Chihuahua	1 798	0.274	0.737	0.732
Jalisco	4 212	0.382	0.758	0.771
Aguascalientes	730	0.311	0.763	0.771
Veracruz	3 243	0.385	0.764	0.792
Campeche	599	0.295	0.881	0.977
San Luis Potosí	2 495	0.202	0.889	0.897
Guerrero	2 046	0.277	0.889	0.951
Ciudad de México	20 942	0.128	0.895	0.858
Tabasco	2 801	0.117	0.942	0.930

Este es el resultado más consistente con la hipótesis H1 en su formulación fuerte: la inequidad geográfica es una propiedad del modelo y no un artefacto de la estructura demográfica de las entidades.

Dos matices impiden sobreinterpretarlo. El primero es de precisión: los subgrupos son pequeños –Chiapas aporta apenas 482 observaciones– de modo que buena parte de la

amplitud del rango es varianza de muestreo y no inequidad estimada con fiabilidad. Los intervalos de confianza de la sección 4.3.2 se calcularon sobre la población completa, no dentro de este subgrupo, donde los tamaños son un orden de magnitud menores; para él sigue sin haber una medida de precisión.

De hecho Chiapas queda por debajo del criterio general de soporte, que se relajó aquí a 300 observaciones (sección 3.4). Aplicando el criterio de 500 quedarían 31 entidades, el peor desempeño sería Chihuahua con 0.7374 y el rango bajaría a 0.204. La conclusión no depende de la elección: bajo cualquiera de los dos criterios la dispersión dentro del subgrupo supera con holgura la de la población completa (0.0563).

El segundo es que la ampliación del rango de AUROC dentro de los adultos mayores matiza el diagnóstico de la sección 4.6. En la población completa la disparidad reside claramente en el umbral y no en el ordenamiento; dentro del subgrupo de 60 años o más, en cambio, la dispersión del AUROC es del mismo orden que la de la sensibilidad, lo que sugiere que ahí también hay un componente de ordenamiento. Si es así, una mitigación basada solo en umbrales sería menos efectiva en ese subgrupo que en la población general. Comprobarlo exige repetir la mitigación dentro del subgrupo, algo que este trabajo no hace.

Conviene además no leer el resultado en clave de marginación. El subgrupo con peor discriminación (Chiapas, grado «Muy alto») no es el de mayor mortalidad –esa es Michoacán, con 0.436 frente a 0.322– y entre los cinco mejores figura Guerrero, la entidad con mayor marginación del país. El patrón por grado de marginación se examina en la sección 4.3.5 y no aparece.

4.3.5. Correlatos de la inequidad geográfica

Se examinó la asociación entre el desempeño por entidad y tres características del grupo. Sobre las 32 entidades:

- **Tamaño de muestra.** $r = +0.194$ ($p = 0.288$); Spearman $\rho = +0.293$ ($p = 0.104$). Asociación positiva débil y no significativa.
- **Tasa de mortalidad de la entidad.** $r = -0.373$ ($p = 0.036$); $\rho = -0.335$ ($p = 0.061$). Es la única asociación que alcanza significación convencional: el modelo discrimina peor en las entidades con mayor mortalidad observada.
- **Índice de marginación.** $r = -0.071$ ($p = 0.700$); $\rho = -0.075$ ($p = 0.684$). Sin asociación detectable. Para la sensibilidad, $r = -0.178$ ($p = 0.328$).

El índice de marginación procede del archivo por entidad de los *Índices de marginación 2020* de CONAPO, contruidos sobre el Censo de Población y Vivienda 2020 (Consejo Nacional de Población, 2021). Conviene precisar su escala, porque se presta a confusión: la edición 2020 se calcula por Distancias Ponderadas al cuadrado y un valor *más alto* indica *menor* marginación –Guerrero 10.99, grado «Muy alto»; Nuevo León 23.44, grado «Muy bajo»–. El «índice normalizado» acotado a $[0, 1]$ pertenece a las ediciones anteriores, basadas en componentes principales, y su dirección es la contraria.

Como una correlación lineal puede ocultar un patrón escalonado, y el grado es la forma en que CONAPO comunica el índice, la tabla 4.9 agrega el desempeño por grado de marginación. No aparece gradiente alguno: el AUROC medio oscila entre 0.940 y 0.949 sin orden discernible, y una prueba de Kruskal–Wallis entre grados no detecta diferencia ($H = 1.827$, $p = 0.768$). Llama la atención que el grupo con menor AUROC medio sea el de marginación *muy bajo*, lo contrario de lo que anticipaba la hipótesis H2.

Tabla 4.9: Desempeño medio por grado de marginación (CONAPO 2020), de mayor a menor carencia. Kruskal–Wallis sobre el AUROC entre grados: $H = 1.827$, $p = 0.768$.

Grado de marginación	Entidades	AUROC medio	TPR medio
Muy alto	3	0.9485	0.793
Alto	9	0.9451	0.808
Medio	8	0.9484	0.816
Bajo	8	0.9486	0.794
Muy bajo	4	0.9399	0.709

4.4. Sensibilidad: la población en la que el desenlace es posible

Como se declaró en la sección 3.2, en esta cohorte fallecer implica estar registrado como hospitalizado. El modelo separa 141 499 defunciones de un conjunto de supervivientes del que la gran mayoría son casos ambulatorios que no pueden fallecer. La tabla 4.10 compara la cohorte completa con el subconjunto hospitalizado, que es la población en riesgo.

El contraste es grande y hay que enunciarlo sin rodeos: el AUROC pasa de 0.9503 a 0.7001. Buena parte de la discriminación de la cohorte completa consiste en separar ambulatorios de hospitalizados, tarea que NEUMONIA al primer contacto resuelve muy bien –lo que explica que domine la importancia por encima de la edad, algo anómalo en un modelo de mortalidad por COVID.

Tabla 4.10: Análisis de sensibilidad: cohorte completa frente al subconjunto hospitalizado, que es donde el desenlace es posible. El AUPRC se acompaña de su razón respecto de la prevalencia, que es su línea base.

	Cohorte completa	Solo hospitalizados
n	2 526 649	297 685
Prevalencia del desenlace	0.056	0.475
AUROC	0.9503	0.7001
AUPRC	0.5533	0.6370
AUPRC / prevalencia	9.88×	1.34×
Brier	0.0323	0.2179
Δ TPR entre entidades	0.2935	0.1876
Δ AUROC entre entidades	0.0563	0.1494

El AUPRC ilustra el mismo punto y advierte contra una lectura ingenua: sube de 0.5533 a 0.6370, pero su línea base es la prevalencia, que pasa de 5.60 % a 0.475. Normalizado, el poder discriminante cae de 9.88× la prevalencia a 1.34×: un AUPRC mayor sobre una señal mucho más débil.

Nada de esto invalida la cohorte principal, que responde a una pregunta legítima –priorizar al primer contacto entre todos los casos confirmados– pero sí fija con qué puede compararse cada cifra. El 0.9503 no es homologable a un modelo de mortalidad hospitalaria; el 0.7001 sí.

4.4.1. Efecto sobre el diagnóstico de equidad

Lo relevante para esta tesis es que la estructura del sesgo cambia. En la población en riesgo la brecha de sensibilidad *baja* de 0.2935 a 0.1876, mientras la de AUROC casi se triplica, de 0.0563 a 0.1494 –con Chiapas en 0.6110 y Tabasco en 0.7604.

Es decir: la disparidad se desplaza del umbral hacia el ordenamiento. El diagnóstico de la sección 4.6 –que el problema está en dónde se corta y no en cómo se ordena– vale para la cohorte completa, pero se invierte parcialmente entre los pacientes hospitalizados. Es el mismo patrón que apareció en el subgrupo de 60 años o más, y con la misma consecuencia práctica: la mitigación por umbrales, que es la que funciona en la cohorte completa, sería menos suficiente en la población clínicamente crítica.

4.4.2. ¿Depende el resultado de una sola variable?

La sección 4.2.2 mostró que NEUMONIA concentra la importancia, y la sección 3.2 advirtió que su validez descansa en un supuesto sobre la práctica de registro. Si la inequidad

geográfica fuera un artefacto de que unos estados registran neumonía mejor que otros, debería desaparecer al quitar esa variable.

No desaparece. Reentrenando con los 12 predictores restantes, el AUROC baja de 0.9503 a 0.8893 –una caída de 0.0609, que confirma su peso– y el AUPRC cae de 0.5533 a 0.3311. Pero la disparidad persiste: la brecha de AUROC entre entidades es 0.0642, ligeramente *mayor* que la de 0.0563 del modelo completo, y la de sensibilidad baja a 0.1529 sin acercarse a desaparecer.

La inequidad geográfica no es, por tanto, un efecto de la práctica de registro de esa variable. Sobrevive a un modelo que no la usa, y con la brecha de discriminación incluso algo más amplia.

4.5. Transportabilidad geográfica interna

Los resultados anteriores evalúan el modelo en entidades que participaron en su entrenamiento. La tabla 4.11 y la figura 4.4 muestran qué ocurre cuando la entidad evaluada fue excluida por completo (sección 3.10).

Tabla 4.11: Transportabilidad geográfica interna: AUROC de cada entidad cuando participó en el entrenamiento frente a cuando fue excluida por completo (seis mayores pérdidas y cuatro mayores ganancias de 32 entidades).

Entidad	n	AUROC interno	AUROC no vista	Δ
Tlaxcala	17 431	0.9391	0.9283	-0.0108
Michoacán	38 126	0.9359	0.9280	-0.0079
Morelos	39 258	0.9600	0.9552	-0.0048
Puebla	75 074	0.9480	0.9435	-0.0045
Colima	25 536	0.9598	0.9558	-0.0040
Guanajuato	118 324	0.9579	0.9539	-0.0040
Yucatán	49 748	0.9440	0.9480	+0.0040
Tamaulipas	63 741	0.9539	0.9592	+0.0053
Campeche	16 881	0.9544	0.9601	+0.0057
Durango	25 123	0.9310	0.9376	+0.0066

El desempeño se transfiere casi intacto. La pérdida mediana de AUROC al no haber visto la entidad es -0.0006, con un rango de $[-0.0108, +0.0066]$: la entidad más afectada, Tlaxcala, pierde -0.0108. De las 32 entidades, 19 empeoran y el resto mejora; solo 1 supera una diferencia absoluta de 0.01.

Las disparidades tampoco se acentúan. La brecha de AUROC entre entidades pasa de 0.0563 a 0.0516 y la de sensibilidad de 0.2935 a 0.2684: ambas se mantienen o se reducen ligeramente.




Figura 4.4: Transportabilidad geográfica interna. Izquierda: AUROC por entidad habiendo participado en el entrenamiento frente a haber sido excluida. Derecha: pérdida frente al tamaño de la entidad.

El resultado tiene una lectura sustantiva que refuerza el argumento central. La pérdida por transportabilidad no guarda relación con el tamaño de la entidad ($r = -0.003$, $p = 0.988$), de modo que el modelo no depende de haber visto un estado concreto para funcionar en él. Combinado con el fracaso de la reponderación (sección 4.6), esto cierra la explicación por representación: la inequidad geográfica no proviene de que el modelo haya visto pocos datos de ciertos estados –se comporta igual sin haber visto ninguno– sino de aplicar una regla de decisión común a poblaciones con distribuciones de riesgo distintas.

La única asociación detectable es con la mortalidad de la entidad ($r = -0.370$, $p = 0.037$): los estados con más defunciones pierden algo más al no haber sido vistos. Es la misma dirección que la correlación entre AUROC y mortalidad de la sección 4.3.5, y apunta al mismo mecanismo pendiente de identificar.

Nota metodológica. Este diseño no sustituye a la validación externa. Que un modelo generalice a un estado no visto *de la misma fuente, el mismo año y el mismo proceso de captura* dice poco sobre si generalizaría a otro sistema de registro. La hipótesis H4 sigue sin poner a prueba.

4.6. Mitigación de sesgo

La tabla 4.12 compara las tres familias de intervención sobre el mismo conjunto de prueba y el mismo punto de operación.

Tabla 4.12: Comparación de las tres familias de mitigación sobre el conjunto de prueba. Menor ΔTPR indica mayor equidad entre entidades.

Intervención	ΔTPR	ΔFPR	Selec.	Exact. bal.
Línea de base (umbral global)	0.294	0.087	0.100	0.868
Pre: reponderación por entidad	0.290	0.082	0.099	0.865
In: <i>equalized odds</i> (Fairlearn) ^a	0.445	–	–	–
Post: umbral por entidad ^b	0.140	0.101	0.102	0.871
Post: umbral por entidad (en muestra) ^c	0.022	0.107	0.101	0.869

^a Evaluado en una submuestra del bloque de entrenamiento ($n = 120\,000$) y con un clasificador lineal; no es comparable uno a uno con las demás filas. La reducción devuelve una distribución sobre clasificadores: sobre 20 realizaciones del mismo modelo ajustado, la brecha tiene mediana 0.397 y rango $[0.245, 0.628]$, intervalo que contiene a la línea de base.

^b Umbrales estimados en el bloque de calibración y evaluados en el de prueba: es la cifra desplegable.

^c Umbrales estimados sobre el propio conjunto de prueba: cota optimista, reportada solo para dimensionar el sesgo de ajuste en muestra.

4.6.1. Pre-procesamiento

La reponderación inversa al tamaño de la entidad deja la brecha de sensibilidad prácticamente intacta: 0.290 frente a 0.294 de la línea de base, con una ligera pérdida de exactitud balanceada. El resultado es informativo: el problema no es que el modelo haya visto pocos datos de las entidades pequeñas, sino que la regla de decisión –un corte único– interactúa mal con distribuciones de riesgo heterogéneas. Reponderar la representación no puede corregir eso.

4.6.2. In-procesamiento

La reducción con restricción de *equalized odds* arroja una brecha de 0.445, es decir, *superior* a la de la línea de base. Pero el número puntual no es lo relevante, y reportarlo solo sería engañoso.

La reducción por gradiente exponenciado no devuelve un clasificador, sino una *distribución* sobre clasificadores, de la que la predicción muestrea. Sobre el mismo modelo ya ajustado y el mismo conjunto de evaluación, 20 realizaciones producen brechas con mediana 0.397 y rango $[0.245, 0.628]$. Ese intervalo contiene a la línea de base (0.294) y

es más ancho que cualquier efecto que pudiera atribuirse a la restricción de equidad: la brecha depende más de qué realización toque que de la intervención.

La interpretación correcta no es que el método sea inadecuado en general, sino que resulta inestable en este régimen: con 32 grupos, algunos con pocos casos positivos, el juego minimax que resuelve el algoritmo persigue la brecha máxima, que en grupos pequeños está dominada por varianza de muestreo. A ello se suman las limitaciones del montaje –submuestra y aprendizaje lineal– que impiden una comparación uno a uno, como se advierte en la propia tabla.

Nota metodológica. Esta dispersión es también una advertencia de reproducibilidad. Si no se fija la semilla en el momento de predecir –y no basta con fijarla al ajustar–, el resultado del método cambia entre ejecuciones sin que nada lo señale. Un trabajo que reportase una sola realización podría concluir tanto que la intervención reduce la brecha como que la duplica.

4.6.3. Post-procesamiento

El ajuste de umbrales por entidad es la única intervención efectiva. Con umbrales estimados en el bloque de calibración y evaluados en el de prueba, la brecha de sensibilidad cae de 0.294 a 0.140, una reducción de 52 %, mientras la exactitud balanceada *mejora* ligeramente, de 0.868 a 0.871, y la tasa de selección global se mantiene en torno a 0.100. Es decir: en este problema la equidad geográfica se puede mejorar sustancialmente sin costo de desempeño agregado.

Nota metodológica. La misma intervención, con umbrales estimados sobre el propio conjunto de prueba, produce una brecha de 0.022. Esa cifra es una cota optimista y no una política desplegable: mide qué tan bien se puede ajustar en retrospectiva, no qué tan bien generalizaría. La diferencia entre 0.022 y 0.140 –un factor de 6.4– dimensiona el sesgo que introduce estimar umbrales en muestra, y es la razón por la que este trabajo reporta la segunda cifra como resultado.

4.6.4. Frontera de Pareto

La tabla 4.13 y la figura 4.5 presentan la frontera obtenida interpolando entre el umbral global y los umbrales por entidad.

La forma de la frontera es el resultado con mayor valor práctico: la exactitud balanceada permanece en la banda 0.866–0.871 a lo largo de todo el recorrido, mientras la brecha de sensibilidad desciende de 0.293 a 0.140. No hay, en este problema, un intercambio

Tabla 4.13: Frontera de Pareto equidad–desempeño. El parámetro α interpola entre el umbral global ($\alpha = 0$) y el umbral por entidad estimado fuera de muestra ($\alpha = 1$). Cada fila es una política de despliegue posible.

α	ΔTPR	Exactitud balanceada	Selección
0.0	0.2935	0.8680	0.1005
0.1	0.2813	0.8672	0.0987
0.2	0.2746	0.8664	0.0977
0.3	0.2491	0.8667	0.0978
0.4	0.2341	0.8693	0.0993
0.5	0.2207	0.8713	0.1004
0.6	0.2207	0.8706	0.0996
0.7	0.2180	0.8700	0.0992
0.8	0.2180	0.8703	0.0998
0.9	0.1840	0.8695	0.0999
1.0	0.1402	0.8711	0.1024




Figura 4.5: Frontera de Pareto equidad–desempeño (izquierda) y desempeño por entidad frente al índice de marginación de CONAPO 2020 (derecha; un valor más alto indica menor marginación).

material entre equidad y desempeño agregado; la resistencia a corregir la disparidad no puede justificarse invocando pérdida de utilidad clínica global.

Conviene señalar que el descenso no es monótono ni suave: entre $\alpha = 0.5$ y $\alpha = 0.8$ la brecha se estanca en torno a 0.218–0.221. Ese estancamiento refleja que la brecha máxima está determinada por unas pocas entidades extremas, y que la interpolación lineal solo las alcanza cuando α se aproxima a 1. Para el despliegue, la lectura es que las políticas intermedias rinden menos de lo que sugeriría una interpolación proporcional.

Capítulo 5

Discusión

5.1. Evaluación de las hipótesis

H1: disparidades entre entidades federativas

Sostenida. Un modelo con AUROC de 0.9503 presenta una brecha de sensibilidad de 0.2935 y una brecha de AUROC de 0.0563 entre entidades. La disparidad persiste al restringir el análisis a adultos de 60 años o más, donde el rango de AUROC va de 0.688 a 0.942, lo que descarta que sea un reflejo de la composición etaria de los estados.

Resiste además dos pruebas de robustez que podrían haberla desmentido. En el subconjunto hospitalizado –la población en la que el desenlace es posible– no solo persiste sino que la brecha de AUROC casi se triplica, hasta 0.1494 (sección 4.4). Y no se debe a la composición del entrenamiento: un modelo que nunca vio una entidad rinde en ella casi igual que uno que sí la vio (sección 4.5).

La formulación original hablaba de disparidades «estadísticamente significativas», y esa cualificación ahora sí puede sostenerse. Ninguna de las 1000 reasignaciones al azar de la etiqueta de entidad produjo una brecha tan grande como la observada, ni en AUROC ni en sensibilidad ($p = 0.001$ y $p = 0.001$, el mínimo alcanzable con ese número de permutaciones), y 53 % de los pares de entidades tienen intervalos de AUROC disjuntos (sección 4.3.2).

El contraste obliga además a matizar la magnitud. La brecha nula no es cero: con 32 grupos desiguales, el azar produce una separación mediana de 0.0737 en sensibilidad. El exceso atribuible a la entidad es de unos 0.2198, no los 0.2935 completos. Sigue siendo una disparidad grande, pero conviene reportarla contra la referencia correcta y no contra cero.

H2: asociación con la infraestructura o marginación

No sostenida. El índice de marginación de CONAPO 2020 no muestra asociación detectable con el desempeño por entidad ($r = -0.071$, $p = 0.700$), y el resultado se sostiene al agregar por grado de marginación, donde una prueba de Kruskal–Wallis tampoco detecta diferencia ($H = 1.827$, $p = 0.768$). El grupo con menor AUROC medio es, de hecho, el de marginación *muy baja*: si hay una tendencia, apunta en dirección opuesta a la hipótesis.

Cabe una advertencia sobre el alcance de esta conclusión. La ausencia de asociación con un índice compuesto no equivale a ausencia de mecanismo estructural: la marginación socioeconómica agregada por entidad es un *proxy* grueso de lo que importaría aquí, que es la capacidad de registro y atención de las unidades médicas. H2 queda refutada en la forma en que se operacionalizó, no en su intuición de fondo.

El único correlato que alcanza significación convencional es la tasa de mortalidad de la entidad ($r = -0.373$, $p = 0.036$): el modelo discrimina peor donde más gente muere. Conviene no sobrevalorarlo: se examinaron tres características por dos métricas y dos estadísticos, de modo que un único p apenas por debajo de 0.05 en una docena de contrastes no sobrevive a ninguna corrección por multiplicidad. Se reporta como señal a investigar, no como hallazgo confirmatorio. Esta asociación admite al menos dos lecturas que el diseño actual no puede separar. Puede reflejar un mecanismo de *atención*: en entidades con sistemas más presionados, la muerte depende más de factores no capturados por el modelo –disponibilidad de cama, oportunidad del traslado, saturación– y menos del perfil clínico inicial, de modo que hay un techo real a lo que la edad y las comorbilidades pueden predecir. Y puede reflejar un mecanismo de *registro*: una mortalidad observada más alta puede indicar subdetección de casos leves, lo que cambia la composición de la cohorte y con ella la dificultad de la tarea. Distinguir ambas requiere indicadores de infraestructura por unidad médica, no por entidad.

H3: mitigación con pérdida acotada de desempeño

Sostenida, con una precisión importante. El post-procesamiento por umbrales de entidad reduce la brecha de sensibilidad de 0.294 a 0.140 –52 %– sin pérdida de desempeño agregado: la exactitud balanceada pasa de 0.868 a 0.871. La frontera de Pareto muestra que el desempeño se mantiene en la banda 0.866–0.871 en todo su recorrido, de modo que la pérdida es inferior a cualquier umbral razonable que se hubiera fijado de antemano.

Hay, sin embargo, un costo que la exactitud balanceada no captura y que conviene enunciar: al igualar la sensibilidad entre entidades, la brecha de *tasa de falsos positivos* empeora, de 0.087 a 0.101. No es un defecto del método sino exactamente lo que predice

el teorema de imposibilidad (capítulo 2): con prevalencias distintas entre grupos, igualar una de las dos tasas de *equalized odds* desiguala la otra. Lo que el post-procesamiento hace no es eliminar la inequidad, sino *elegir* cuál de las dos se reparte por igual –y elegir la sensibilidad, en un instrumento cuyo costo de omitir una defunción excede al de una alarma innecesaria, es defendible. Pero es una elección normativa que debe declararse, no un óptimo técnico.

La segunda precisión es que la mitigación *no elimina* la disparidad. Una brecha residual de 0.140 sigue siendo clínicamente relevante. Y el hallazgo metodológico que acompaña al resultado es que la cifra de eliminación casi total que se obtiene ajustando umbrales sobre el propio conjunto de prueba (0.022) es un artefacto de ajuste en muestra. Un trabajo que no separase el bloque de calibración concluiría que el problema queda resuelto, cuando la brecha desplegable es 6.4 veces mayor.

H4: transportabilidad a una fuente independiente

Sin poner a prueba, con evidencia parcial en la dirección contraria a lo esperado. La validación externa en la base de Egresos Hospitalarios de la DGIS no se ha ejecutado, de modo que H4 tal como está redactada –transferencia a una *fente independiente*– no queda ni sostenida ni refutada.

Sí se puso a prueba la generalización geográfica dentro de la misma fuente (sección 4.5), y el resultado va en contra de lo que H4 anticipaba: al excluir por completo una entidad del entrenamiento, el desempeño sobre ella apenas cambia (pérdida mediana -0.0006) y las disparidades no se acentúan, sino que se mantienen o se reducen. Esto acota la hipótesis: si las disparidades llegaran a agravarse en la base DGIS, no sería por no haber visto la entidad, sino por el cambio de fuente, de definición de caso o de periodo.

La ejecución futura de H4 tiene además un prerequisite que este trabajo identificó y conviene dejar escrito. SAEH es una base de *egresos*: su población son pacientes hospitalizados, con una prevalencia del desenlace cercana a 0.475 frente a 5.60 % en esta cohorte. Aplicar sobre ella el modelo principal produciría una caída de desempeño atribuible al cambio de espectro y no a la transportabilidad. La validación externa debe hacerse con el modelo restringido a hospitalizados de la sección 4.4, no con el de la cohorte completa.

5.2. Asimetría entre familias de mitigación

El resultado comparativo tiene, a nuestro juicio, valor propio. Las tres familias de mitigación se presentan habitualmente como alternativas de eficacia comparable, a elegir según

restricciones operativas. En este problema la diferencia es cualitativa: el pre-procesamiento no mueve la brecha, el in-procesamiento arroja un resultado tan disperso que no permite concluir nada –su rango entre realizaciones, $[0.245, 0.628]$, contiene a la línea de base– y solo el post-procesamiento la reduce, a la mitad y sin costo agregado.

La explicación está en la naturaleza del sesgo. La disparidad no proviene de un ordenamiento defectuoso: el AUROC por entidad es alto en todas (0.9207–0.9770), y el modelo está bien calibrado en cada una (error máximo 0.0231). Proviene de aplicar un *corte único* a distribuciones de riesgo que difieren entre entidades. Cuando el defecto está en la regla de decisión y no en la función de puntuación, la intervención que corrige la regla de decisión es la que funciona. Reponderar los datos de entrenamiento ataca un problema de representación que aquí no es el que causa la brecha.

Esto sugiere una heurística transferible: antes de elegir la familia de mitigación, conviene diagnosticar si la inequidad reside en el ordenamiento –brechas de AUROC grandes– o en el umbral –AUROC similar con brechas de TPR grandes. Aquí la brecha de sensibilidad (0.2935) es 5.2 veces la de AUROC (0.0563), lo que apuntaba al umbral desde el diagnóstico. Ese diagnóstico, sin embargo, es específico de la cohorte completa. Entre los pacientes hospitalizados la relación se invierte –la brecha de AUROC sube a 0.1494 y la de sensibilidad baja a 0.1876– y en el subgrupo de 60 años o más la dispersión del AUROC llega a 0.254. La heurística, por tanto, no es «diagnostíquese una vez», sino «diagnostíquese en la población sobre la que se va a desplegar»: en la población en riesgo, una mitigación basada solo en umbrales sería insuficiente.

5.3. Implicaciones para el despliegue

1. **Un umbral nacional único no es una decisión neutral.** Es una decisión que redistribuye sensibilidad entre entidades. Conviene precisar en qué dirección: la sensibilidad por entidad *no* está asociada a su mortalidad ($r = +0.165$, $p = 0.366$), de modo que el reparto no penaliza sistemáticamente a los estados con más defunciones; lo que sí decae en ellos es la discriminación ($r = -0.373$, $p = 0.036$). La inequidad de sensibilidad no sigue un eje interpretable, y eso la hace más difícil de justificar, no menos: la neutralidad aparente de «el mismo umbral para todos» reparte la protección de forma esencialmente arbitraria entre estados.
2. **La frontera de Pareto es el entregable adecuado para el regulador.** La elección de α es normativa. El análisis técnico puede mostrar que no cuesta desempeño agregado; no puede decidir cuánta diferenciación por entidad es aceptable en términos de equidad horizontal entre ciudadanos.

3. **Umbral por entidad plantean una objeción legítima.** Usar la residencia en el momento de la decisión implica tratar de forma distinta a dos pacientes con idéntico perfil clínico. La justificación es que el trato formalmente idéntico ya produce resultados desiguales; pero es un argumento que debe hacerse explícito ante un comité de ética, no asumirse.
4. **La calibración debe verificarse antes de auditar equidad.** Como muestra el capítulo 4, auditar sobre puntajes descalibrados habría producido una conclusión invertida sobre la calibración por grupo.
5. **Humano en el circuito.** Con una tasa de selección de 0.100 y un valor predictivo positivo modesto en el punto de operación, el instrumento es de priorización y no de decisión automatizada.

5.4. Relación con la literatura

El modelo de referencia coincide con la literatura sobre esta base (Becerra-Sánchez et al., 2022; Méndez-Astudillo, 2024) en las variables que resultan más informativas –neumonía y edad– lo que respalda que el sujeto de la auditoría sea representativo y no un modelo debilitado. Una comparación numérica directa del desempeño no es posible, porque esos trabajos reportan exactitud y F_1 sobre umbrales no declarados y esta tesis reporta AUROC y sensibilidad en un punto de operación explícito.

Respecto del trabajo que estudia los factores geográficos como predictores (Maldonado-Sifuentes et al., 2024), los resultados de esta tesis son complementarios y no contradictorios. Que la entidad sea informativa como predictor y que el modelo sea desigualmente preciso entre entidades son hechos distintos; el segundo es el que importa para el despliegue responsable, y es el que no se había medido. Es de notar que el modelo auditado aquí *no* usa la entidad como predictor, y aun así su desempeño depende de ella: la inequidad geográfica no requiere que la geografía entre al modelo.

Frente a la literatura de equidad en salud anclada en otros contextos (Nejadshamsi et al., 2026; Ricci Lara et al., 2022), la aportación es el traslado del marco a un atributo sensible –la entidad federativa– con significado institucional propio en México, donde la desigualdad entre estados es un rasgo estructural del sistema y no una variable de composición poblacional. Que el índice de marginación no explique la brecha no debilita esa elección: confirma que la entidad captura algo que los agregados socioeconómicos estatales no miden, y esa es precisamente la razón para auditarla como atributo propio.

5.5. Limitaciones

1. **Sin validación externa.** Todo el análisis vive en una fuente y un año. La generalización geográfica interna sí se evaluó (sección 4.5) y resultó buena, pero no sustituye a una segunda fuente.
2. **El desenlace vive en el 11.8 % de la cohorte.** Fallecer implica estar registrado como hospitalizado, de modo que parte de la discriminación del modelo principal es separar ambulatorios de hospitalizados. Las cifras comparables con modelos clínicos de mortalidad son las de la sección 4.4, no las de la cohorte completa.
3. **Incertidumbre acotada solo en el eje principal.** La auditoría por entidad se acompaña de intervalos de confianza y prueba de permutación, pero los subgrupos interseccionales y los ejes de sexo y edad se reportan como estimaciones puntuales. El ordenamiento fino de la tabla 4.3 tampoco debe leerse posición por posición: solo 53 % de los pares tienen intervalos disjuntos.
4. **Marginación medida a escala estatal.** El índice de CONAPO está verificado, pero agrega condiciones socioeconómicas por entidad. El mecanismo que H2 postula –capacidad de atención– opera a escala de unidad médica, de modo que la ausencia de asociación acota la hipótesis pero no la cierra.
5. **Un solo año y un solo desenlace.** No se modela hospitalización ni se evalúa estabilidad temporal entre olas epidémicas, cuya composición de casos y presión hospitalaria difieren de forma conocida.
6. **Sesgo de verificación en la cohorte.** Restringir a casos confirmados condiciona a haber sido detectado y probado, y la propensión a detectar varía entre entidades. Parte de la disparidad observada puede originarse en el proceso de captura y no en el modelo. Este es, a nuestro juicio, el supuesto más frágil del diseño y no puede corregirse dentro de esta fuente.
7. **Dependencia de una variable.** Con NEUMONIA concentrando la importancia, un cambio en la práctica de registro entre entidades se traduciría directamente en desempeño desigual. Falta el análisis de sensibilidad que lo descarte.
8. **Validación por partición aleatoria.** No se realizó validación temporal ni dejando-una-entidad-fuera, que es el diseño natural para evaluar generalización geográfica.

Capítulo 6

Conclusiones y trabajo futuro

6.1. Conclusiones

Esta tesis partió de una premisa que la literatura respalda: predecir mortalidad por COVID-19 con datos abiertos mexicanos es un problema resuelto. Sobre esa base desplazó la pregunta de si el modelo acierta a si acierta por igual, tomando la entidad federativa como atributo sensible. Las conclusiones son cinco.

Primera: la inequidad geográfica existe y es sustantiva. Un modelo con AUROC de 0.9503 reparte su sensibilidad de forma muy desigual entre estados: la brecha es 0.2935 en un punto de operación calibrado para detectar el 80 % de las defunciones a escala nacional. Traducido, el modelo detecta cerca de 69 de cada 100 defunciones en la entidad peor servida frente a 88 en la mejor. La disparidad es estadísticamente significativa ($p = 0.001$ frente a la nula por permutación), aunque conviene descontar lo que el azar aporta con 32 grupos desiguales: el exceso atribuible a la entidad es de unos 0.2198. Y ocurre *sin* que la entidad sea un predictor del modelo, lo que descarta la solución ingenua de «no usar la geografía».

Segunda: no se explica por composición demográfica. Al restringir el análisis a adultos de 60 años o más, la brecha no solo persiste sino que se amplía. La inequidad es una propiedad del modelo operando sobre poblaciones heterogéneas, no un artefacto de la estructura de edades de cada estado.

Tercera: en la población completa la disparidad reside en el umbral, no en el ordenamiento, y eso determina qué mitigación funciona. El AUROC por entidad es alto en todas y la calibración por entidad es buena (error máximo 0.0231); lo que falla es aplicar un corte único a distribuciones de riesgo distintas. La salvedad importa: entre los pacientes hospitalizados –la población donde el desenlace es posible– la relación se invierte, con la brecha de AUROC en 0.1494 y la de sensibilidad en 0.1876, y en el subgrupo de 60 años o más la dispersión del AUROC llega a 0.254. El diagnóstico, y con él

la elección de mitigación, debe hacerse sobre la población en la que se desplegará. Por eso la reponderación previa al entrenamiento no cambia nada, la restricción de *equalized odds* durante el entrenamiento resulta inestable con 32 grupos desiguales, y solo el ajuste de umbrales por entidad reduce la brecha –de 0.294 a 0.140, un 52 %– y lo hace *sin* costo de desempeño agregado (exactitud balanceada de 0.868 a 0.871). El costo está en otra parte y es el que predice la teoría: al igualar la sensibilidad, la brecha de falsos positivos crece de 0.087 a 0.101. La mitigación no elimina la inequidad; elige cuál de las dos tasas se reparte por igual. La recomendación práctica que se desprende es diagnosticar primero dónde vive el sesgo –brechas de AUROC frente a brechas de sensibilidad– y elegir la familia de mitigación en consecuencia.

Cuarta: la inequidad no es un problema de cobertura de datos. Al excluir por completo una entidad del entrenamiento y evaluar sobre ella, el desempeño apenas se mueve –pérdida mediana de AUROC -0.0006 sobre 32 entidades– y las brechas no se acentúan. La pérdida además no guarda relación con el tamaño de la entidad ($r = -0.003$, $p = 0.988$). Junto con el fracaso de la reponderación, esto descarta la explicación más intuitiva: el modelo no falla en unos estados por haber visto pocos datos suyos; funciona igual sin haber visto ninguno. Tampoco es un efecto de la práctica de registro de la variable dominante: al reentrenar sin NEUMONIA la brecha de AUROC no se reduce, sino que sube a 0.0642. Lo que produce la inequidad es aplicar una regla común a poblaciones distintas.

Quinta: la separación metodológica no es un detalle. Dos decisiones de diseño cambian conclusiones sustantivas. Auditar la calibración por grupo sobre puntajes sin calibrar habría reportado un error de 0.2108 y una conclusión de «calibración inequitativa» que corresponde en realidad al sesgo global de entrenamiento; medido sobre riesgo calibrado, el error es 0.0231 y la calibración por entidad es buena. Y estimar los umbrales de mitigación sobre el propio conjunto de prueba habría llevado a declarar la brecha prácticamente eliminada (0.022) cuando la cifra desplegable es 0.140, 6.4 veces mayor.

Estas conclusiones se sostienen dentro de los límites declarados en la sección 1.6 y con las limitaciones de la sección 5.5. En particular, la hipótesis H2 queda refutada en la forma en que se operacionalizó –el índice de marginación estatal no predice el sesgo– y la hipótesis H4 sin poner a prueba, si bien la generalización geográfica interna, que es lo más cercano que puede evaluarse sin una segunda fuente, resultó buena.

6.2. Trabajo futuro

Ordenado por prioridad, entendida como la capacidad de cada tarea para modificar las conclusiones anteriores:

1. **Extender la cuantificación de incertidumbre.** El eje geográfico ya cuenta con intervalos de confianza y prueba de permutación (sección 4.3.2); falta hacer lo propio con los subgrupos interseccionales, donde los tamaños son mucho menores y la precisión es la principal duda abierta.
2. **Indicadores de infraestructura de salud.** El índice de marginación de CONAPO ya está incorporado y no explica el sesgo. El paso siguiente es sustituirlo por el mecanismo que H2 postula en realidad: camas, personal y equipamiento por habitante, idealmente por unidad médica y no por entidad.
3. **Validación externa en la base DGIS.** Es el paso que pone a prueba H4 y el que la literatura casi nunca da. Tiene un prerrequisito que este trabajo dejó identificado: SAEH es una base de egresos y su población son pacientes hospitalizados, con una prevalencia del desenlace cercana a 0.475 frente a 5.60 % aquí. Debe validarse el modelo restringido a hospitalizados (sección 4.4); usar el de la cohorte completa haría pasar un cambio de espectro por un fallo de transportabilidad. Requiere además reconstruir las once comorbilidades desde los códigos CIE-10 de SAEH, lo que añade desplazamiento de medición al de población.
4. **Validación temporal.** Dividir por olas epidémicas y entrenar en un año para evaluar en otro, con los cortes anuales de la DGE. La generalización geográfica ya se evaluó (sección 4.5); la temporal no.
5. **Umrales por grupo con regularización.** Contraer los umbrales de entidades pequeñas hacia el umbral global, en lugar de estimarlos de forma independiente. Es la vía natural para atacar la brecha residual de 0.140 sin perseguir ruido.
6. **Sesgo de verificación.** Modelar explícitamente la propensión a la detección por entidad, para separar la inequidad del modelo de la inequidad del proceso de captura.
7. **Desenlace de hospitalización y utilidad clínica.** Extender el análisis al segundo desenlace y añadir análisis de curva de decisión (*net benefit*) (Vickers & Elkin, 2006) y explicaciones locales, previstos en el protocolo y no ejecutados.

Referencias

- Becerra-Sánchez, A., Rodarte-Rodríguez, A., Escalante-García, N. I., Olvera-González, J. E., De la Rosa-Vargas, J. I., Zepeda-Valles, G., & Velásquez-Martínez, E. d. J. (2022). Mortality Analysis of Patients with COVID-19 in Mexico Based on Risk Factors Applying Machine Learning Techniques. *Diagnostics*, 12(6), 1396. <https://doi.org/10.3390/diagnostics12061396>
- Bird, S., Dudík, M., Edgar, R., Horn, B., Lutz, R., Milan, V., Sameki, M., Wallach, H., & Walker, K. (2020). *Fairlearn: A toolkit for assessing and improving fairness in AI* (Informe técnico N.º MSR-TR-2020-32). Microsoft Research. <https://www.microsoft.com/en-us/research/publication/fairlearn-a-toolkit-for-assessing-and-improving-fairness-in-ai/>
- Chouldechova, A. (2017). Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments. *Big Data*, 5(2), 153-163. <https://doi.org/10.1089/big.2016.0047>
- Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. (2015). Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis (TRIPOD): The TRIPOD Statement. *Annals of Internal Medicine*, 162(1), 55-63. <https://doi.org/10.7326/M14-0697>
- Consejo Nacional de Población. (2021). *Índices de marginación 2020* [Archivo por entidad federativa IME_2020.xls; método de Distancias Ponderadas al cuadrado (DP2), con base en el Censo de Población y Vivienda 2020 del INEGI]. Gobierno de México. <https://www.gob.mx/conapo/documentos/indices-de-marginacion-2020-284372>
- Hardt, M., Price, E., & Srebro, N. (2016). Equality of Opportunity in Supervised Learning. *Advances in Neural Information Processing Systems 29 (NIPS 2016)*, 3315-3323.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 3146-3154.
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. *8th Innovations in Theoretical Computer Science*

- Conference (ITCS 2017)*, 67, 43:1-43:23.
<https://doi.org/10.4230/LIPIcs.ITCS.2017.43>
- Maldonado-Sifuentes, C. E., Vargas-Santiago, M., Leon-Velasco, D. A., Ortega-García, M. C., Ledo-Mezquita, Y., & Castillo-Velasquez, F. A. (2024). Leveraging Machine Learning to Unveil the Critical Role of Geographic Factors in COVID-19 Mortality in Mexico. *Computación y Sistemas*, 28(1), 5-18.
<https://doi.org/10.13053/CyS-28-1-4908>
- Méndez-Astudillo, J. (2024). The impact of comorbidities and economic inequality on COVID-19 mortality in Mexico: a machine learning approach. *Frontiers in Big Data*, 7, Artículo 1298029. <https://doi.org/10.3389/fdata.2024.1298029>
- Nejadshamsi, S., H. Chu, C., McGilton, K. S., Li, X., Ronquillo, C., & Abbasgholizadeh-Rahimi, S. (2026). Evaluation and improvement of algorithmic fairness for COVID-19 severity classification using Explainable Artificial Intelligence-based bias mitigation. *JAMIA Open*, 9(1), Artículo ooaf171.
<https://doi.org/10.1093/jamiaopen/ooaf171>
- Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464), 447-453. <https://doi.org/10.1126/science.aax2342>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Ricci Lara, M. A., Echeveste, R., & Ferrante, E. (2022). Addressing fairness in artificial intelligence for medical imaging. *Nature Communications*, 13(1), Artículo 4581.
<https://doi.org/10.1038/s41467-022-32186-3>
- Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17(1), Artículo 230. <https://doi.org/10.1186/s12916-019-1466-7>
- Vickers, A. J., & Elkin, E. B. (2006). Decision Curve Analysis: A Novel Method for Evaluating Prediction Models. *Medical Decision Making*, 26(6), 565-574.
<https://doi.org/10.1177/0272989X06295361>
- Wynants, L., Van Calster, B., Collins, G. S., Riley, R. D., Heinze, G., Schuit, E., Albu, E., Arshi, B., Bellou, V., Bonten, M. M. J., Dahly, D. L., Damen, J. A., Debray, T. P. A., de Jong, V. M. T., De Vos, M., Dhiman, P., Ensor, J., Gao, S., Haller, M. C., ... van Smeden, M. (2020). Prediction models for diagnosis and

prognosis of covid-19: systematic review and critical appraisal. *BMJ*, m1328.
<https://doi.org/10.1136/bmj.m1328>

Zadrozny, B., & Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. *Proceedings of the eighth ACM SIGKDD international conference on Knowledge discovery and data mining*, 694-699.
<https://doi.org/10.1145/775047.775151>

Apéndice A

Reproducibilidad del canal analítico

A.1. Estructura y orden de ejecución

El análisis se implementa en seis cuadernos de Jupyter que deben ejecutarse en orden, más un módulo compartido que fija el contrato entre ellos:

A.2. Contrato de datos entre etapas

El riesgo característico de un canal por cuadernos es que una etapa consuma un artefacto producido por una versión anterior de la etapa previa, sin que nada lo señale. Para evitarlo, cada etapa verifica la procedencia de lo que consume antes de usarlo:

1. El cuaderno 01 escribe, junto al conjunto de datos limpio, un **manifiesto** en JSON con la cohorte empleada, el número de filas, la lista de columnas, las tasas de desenlace y las versiones de biblioteca.
2. Los cuadernos 02 a 04 llaman a `cargar_cohorte()`, que exige la presencia del manifiesto y verifica columnas requeridas, número de filas y bandera de cohorte. Cualquier discrepancia detiene la ejecución con un mensaje accionable en lugar de continuar.
3. El modelo se persiste como **paquete** –estimador, calibrador, lista de predictores, hiperparámetros y huella de la cohorte– y no como estimador desnudo. `cargar_modelo()` rechaza un modelo entrenado sobre otra cohorte o con otros predictores.
4. La escritura del conjunto limpio **falla de inmediato** si no puede completarse, en lugar de degradar a otro formato: una degradación silenciosa dejaría en disco el artefacto de la corrida anterior.

Tabla A.1: Artefactos del canal analítico.

Componente	Función	Salidas
<code>tesis_common.py</code>	Contrato compartido: rutas, co- horte, hiperparámetros, parti- ción, punto de operación y métri- cas de equidad	—
<code>01_exploracion_datos_dge</code>	Ingesta, recodificación, control de fuga, análisis exploratorio	<code>*.parquet</code> , <code>*.manifest.json</code> , <code>calidad_datos.json</code> , figura del EDA
<code>02_modelo_referencia</code>	Entrenamiento, calibración isotó- nica, punto de operación, impor- tancia y sensibilidad al subcon- junto hospitalizado y a la exclu- sión de NEUMONIA	<code>modelo_hgb_mortalidad</code> <code>.joblib</code> , <code>modelo</code> <code>_referencia.json</code> , <code>sensibilidad</code> <code>_hospitalizados.json</code>
<code>03_auditoria_equidad</code>	Auditoría por entidad, sexo, edad e interseccional	<code>auditoria</code> <code>_equidad.json</code> , <code>figu-</code> <code>ra de equidad</code>
<code>04_mitigacion_pareto</code>	Correlatos, tres familias de miti- gación, frontera de Pareto	<code>resultados_tesis.json</code> , figura de Pareto
<code>05_transportabilidad_loeo</code>	Dejar-una-entidad-fuera: 32 mo- delos, cada uno excluyendo una entidad	<code>transportabilidad</code> <code>_loeo.json</code> , <code>figura de</code> <code>transportabilidad</code>
<code>06_incertidumbre</code>	Remuestreo (1000 réplicas) y prueba de permutación (1000) so- bre las brechas	<code>incertidumbre</code> <code>_brechas.json</code> , <code>figu-</code> <code>ra de incertidumbre</code>
<code>generar_tablas.py</code>	Traduce los JSON a tablas y ma- cros de $\text{\LaTeX}$	<code>tesis/tablas/</code> , <code>macros</code> <code>_resultados.tex</code>

El cuaderno 05 es la única excepción deliberada a la regla de que solo el 02 entrena: su objeto de estudio *es* un conjunto de modelos que nunca vieron la entidad evaluada. El 06 no entrena: reconstruye el escenario auditado y solo remuestrea sobre él. Usa los hiperparámetros canónicos, de modo que la única diferencia con la línea de base es qué entidades entraron al ajuste.

Los hiperparámetros del modelo, la partición, el punto de operación, los cortes de edad y las métricas de equidad tienen una única definición, en `tesis_common.py`. Ninguna etapa los redefine, de modo que la alineación entre cuadernos es estructural y no depende de que coincidan por convención.

A.3. Determinismo

Todas las operaciones estocásticas usan semilla fija (42, salvo la submuestra del método de in-procesamiento, que usa 3). La partición se deriva de índices posicionales estratificados por el desenlace, de modo que los bloques de entrenamiento, calibración y prueba son idénticos en los cuadernos 02, 03 y 04.

Un caso merece mención aparte porque no se resuelve fijando la semilla del ajuste. La reducción por gradiente exponenciado de Fairlearn devuelve una distribución sobre clasificadores, y su método de predicción *muestrea* de ella: sin una semilla en la llamada a predecir, la misma ejecución sobre el mismo modelo ya ajustado produce brechas distintas. Al detectarlo se midió el efecto –brechas entre 0.245 y 0.628 sobre 20 realizaciones– y se fijó la semilla también en la predicción. Sin esa corrección, el resultado del método de in-procesamiento no era reproducible entre ejecuciones.

A.4. Entorno de ejecución

Tabla A.2: Versiones utilizadas para producir los resultados de este documento.

Componente	Versión	Componente	Versión
Python	3.14.5	<code>scipy</code>	1.18.0
<code>numpy</code>	2.5.1	<code>fairlearn</code>	0.14.0
<code>pandas</code>	3.0.5	<code>matplotlib</code>	3.11.1
<code>scikit-learn</code>	1.9.0	<code>joblib</code>	1.5.3
<code>pyarrow</code>	25.0.0	TeX Live	2026

A.5. Reproducción del documento

1. Colocar el corte anual `COVID19MEXICO2021.csv` en el directorio raíz, o apuntar a él con la variable de entorno `DGE_DATA_PATH`.
2. Ejecutar los seis cuadernos en orden.
3. Ejecutar `python3 generar_tablas.py` para regenerar tablas y macros.
4. Compilar con `latexmk -pdf tesis.tex` desde el directorio `tesis/`.

Las cifras del capítulo 4 no se editan a mano en ningún punto: provienen de macros generadas desde los archivos de resultados. Si una cifra del texto no coincide con los cuadernos, es porque el paso 3 no se ejecutó, no porque el texto y el análisis discrepen.

Apéndice B

Variables y codificación

B.1. Codificación de la fuente

La base de la DGE codifica las variables categóricas con enteros y reserva valores especiales para la ausencia de dato:

Tabla B.1: Códigos de la fuente relevantes para este trabajo.

Variable	Codificación
Comorbilidades y signos	1 = sí; 2 = no; 97 = no aplica; 98 = se ignora; 99 = no especificado
SEXO	1 = mujer; 2 = hombre; 99 = no especificado
TIPO_PACIENTE	1 = ambulatorio; 2 = hospitalizado; 99 = no especificado
FECHA_DEF	Fecha de defunción; 9999-99-99 indica paciente vivo
CLASIFICACION_FINAL	1, 2, 3 = caso COVID confirmado; 6 = sospechoso; 7 = negativo
ENTIDAD_RES	1-32 entidades federativas; 97-99 desconocido

B.2. Variables derivadas

B.3. Predictores admitidos y variables excluidas

Los trece predictores del modelo son la edad, el indicador de sexo y las once comorbilidades binarizadas: diabetes, EPOC, asma, inmunosupresión, hipertensión, otra comorbilidad, enfermedad cardiovascular, obesidad, enfermedad renal crónica, tabaquismo y neumonía.

Quedan excluidas por posterioridad al punto de predicción, y por tanto por riesgo de fuga de información: UCI, INTUBADO y FECHA_DEF –salvo como origen del desenlace– así

Tabla B.2: Variables construidas y su papel en el análisis.

Variable	Papel	Definición
<code>defuncion</code>	Desenlace	1 si <code>FECHA_DEF</code> $\neq$ 9999-99-99
<code>hospitalizado</code>	Desenlace (no modelado)	1 si <code>TIPO_PACIENTE</code> = 2
<code>EDAD</code>	Predictor	Valores fuera de [0, 120] marcados como faltantes
<code>sexo_mujer</code>	Predictor y atributo sensible	1 = mujer, 0 = hombre, faltante si 99
<code><comorbilidad>_bin</code>	Predictor	1 si el código es 1; 0 si es 2; faltante en otro caso
<code><comorbilidad>_na</code>	Indicador de calidad	1 si el código original es 97, 98 o 99
<code>entidad_nombre</code>	Atributo sensible	Nombre de la entidad de residencia; eje central de la auditoría
<code>grupo_edad</code>	Atributo sensible	Cortes 0–17, 18–39, 40–59, 60 o más

como `TIPO_PACIENTE` en su papel de predictor de mortalidad. La entidad de residencia y el grupo etario se excluyen por una razón distinta: se reservan como atributos sensibles para la auditoría, no por fuga.

Los indicadores `_na` no se emplean como predictores en el modelo reportado, pero se conservan en el conjunto de datos porque el dato faltante resulta informativo y su frecuencia difiere entre entidades por un margen amplio –de 0.02 % a 5.55 %–, lo que constituye un mecanismo plausible de inequidad. El capítulo 4 lo documenta; explotarlo o corregirlo queda como trabajo futuro.